

Abstract

Les machines de Tsetlin constituent une alternative interprétable et efficace matériellement aux réseaux de neurones, mais leur analyse théorique reste difficile en raison des interactions entre automates au sein des clauses. Des approches récentes, telles que Probabilistic Concept Learning (PCL), découplent les automates et introduisent, pour chaque clause, un paramètre de transition $p_k \in (1/2, 1)$ afin de rendre leur analyse théorique possible. Contrairement à PCL, qui conserve des mécanismes de mise à jour distincts pour les exemples positifs et négatifs, nous introduisons une règle locale unique à quatre cas. Chaque automate associé à un littéral est mis à jour uniquement à partir de la paire (x_i, y) , sans dépendre de la sortie de la clause ni du vote de l'ensemble. Cette structure permet de modéliser exactement chaque automate comme une chaîne de Markov naissance–mort à $2N$ états.

Nous dérivons sa distribution stationnaire et caractérisons les régimes d'inclusion et d'exclusion des littéraux sous une loi jointe arbitraire $P(X, Y)$. Pour une clause comportant n variables, dont K sont fixées par une condition, nous montrons que

$$\limsup_{t \rightarrow \infty} \mathbb{P}(C_t \neq C^*) \leq 2(n - K)\gamma_{\min}^{-N},$$

où C^* désigne la configuration de littéraux stationnairement préférée par la dynamique et où $\gamma_{\min} > 1$ mesure le plus faible biais d'inclusion ou d'exclusion parmi les automates. Nous intégrons ensuite cette règle dans un classifieur one-vs-rest composé de clauses soumises à des conditions aléatoires et agrégées par une pondération de type AdaBoost. Nous donnons également des conditions explicites d'identifiabilité de la conjonction génératrice sous dépendance et déséquilibre arbitraires des features, et montrons que cette conjonction reste récupérable sous un bruit de labels arbitraire de probabilité $\eta < \mu/(S + a)$. Sur le protocole de récupération de conjonction de PCL (cible aléatoire, table de vérité complète, sans bruit), notre règle récupère la cible exactement dans 100/100 essais jusqu'à $n=12$ littéraux, contre une dégradation nette de PCL (99% à $n=4$, 37% à $n=12$). Intégrée dans un classifieur one-vs-rest conditionné et boosté par AdaBoost, la règle atteint par ailleurs $100\% \pm 0\%$ sur XOR bruité et des performances compétitives sur Iris, Digits et MNIST (détail des budgets de calcul en Section 6). Les garanties théoriques portent sur la règle locale sous une loi $P(X, Y)$ fixe ; l'ensemble conditionné et boosté évalué expérimentalement entraîne chaque clause sous une distribution adaptative Q_m qui change à chaque round de boosting. Nous montrons que ces mêmes garanties s'appliquent telles quelles à chaque round pris isolément (avec P remplacée par Q_m), mais la convergence du vote pondéré final combinant tous les rounds reste ouverte.

1 Introduction

Les machines de Tsetlin (TM) apprennent des clauses conjonctives de littéraux à l'aide d'un ensemble d'automates finis, un par littéral candidat, mis à jour par un mécanisme de feedback de Type I / Type II. Ce mécanisme couple les automates entre eux : la mise à jour de chaque automate dépend non seulement de l'exemple courant, mais aussi de la sortie de la clause tout entière et du vote global de l'ensemble. Ce couplage rend l'analyse théorique de la dynamique de convergence difficile : même pour une seule clause, les automates n'évoluent pas comme des chaînes de Markov indépendantes, et

la littérature manque encore de garanties de convergence exactes sous une distribution de données arbitraire.

Probabilistic Concept Learning (PCL) est l’approche la plus proche de la nôtre : elle découple les automates et associe à chaque clause un unique paramètre de transition $p_k \in (1/2, 1)$, ce qui permet d’obtenir un résultat de convergence qualitatif. Cette simplification reste néanmoins partielle : PCL conserve des règles de mise à jour distinctes selon que l’exemple est positif ou négatif, et son analyse ne caractérise pas exactement la loi stationnaire de chaque automate sous une distribution de données arbitraire.

Nous proposons une règle locale différente, à quatre cas, où la mise à jour d’un automate ne dépend que de la paire (x_i, y) – ni de la sortie de la clause, ni des autres automates, ni du vote de l’ensemble. Ce découplage total permet de modéliser exactement chaque automate comme une chaîne de Markov naissance–mort réfléchie à $2N$ états, et d’en dériver la loi stationnaire exacte sous une loi jointe $P(X, Y)$ arbitraire.

Contributions. (1) Une règle de mise à jour locale à quatre cas, découplée de la sortie de la clause et du vote de l’ensemble. (2) La loi stationnaire exacte de chaque automate sous une loi $P(X, Y)$ arbitraire, et la caractérisation des trois régimes de sélection d’un littéral qui en découlent. (3) Une borne de concentration structurelle multi-features en $2(n - K)\gamma_{\min}^{-N}$ pour une clause entière. (4) Des conditions explicites d’identification de la conjonction génératrice sous dépendance et déséquilibre arbitraires des features, et sa récupération sous un bruit de labels arbitraire de probabilité $\eta < \mu/(S + a)$. (5) Un classifieur one-vs-rest pratique combinant cette règle, des conditions aléatoires et un poids de type AdaBoost, évalué sur XOR bruité, Iris, Digits et MNIST.

2 Contexte et travaux connexes

2.1 Machines de Tsetlin

Une clause TM est une conjonction de littéraux x_i ou $\neg x_i$, chacun gouverné par un automate à $2N$ états dont la moitié inférieure correspond à l’action Exclude et la moitié supérieure à l’action Include. Le feedback dépend du label y , de la sortie de la clause, et – pour le Type II en particulier – du vote global de l’ensemble sur cet exemple : le Type I renforce les littéraux cohérents avec un exemple positif que la clause reconnaît, le Type II pénalise les littéraux inclus à tort sur un exemple négatif. Notre seul objectif ici est de préciser ce que notre règle retire à ce mécanisme : la dépendance à la sortie de la clause et au vote de l’ensemble.

2.2 Probabilistic Concept Learning

PCL découple les automates d’une même clause et leur associe, pour chacune, un paramètre de transition unique $p_k \in (1/2, 1)$: la mise à jour de chaque automate suit une marche aléatoire biaisée par p_k , avec des règles différentes selon que l’exemple observé est positif ($y = 1$) ou négatif ($y = 0$) (mécanisme vérifié directement dans le code officiel des auteurs, `dpcl-classifier/Main_code_AAAI25`). Sous cette hypothèse, PCL établit un résultat de convergence garantissant la récupération d’une conjonction

cible.

PCL conserve une structure de feedback héritée des machines de Tsetlin et fournit un résultat de convergence qualitatif sous des hypothèses spécifiques sur p_k . Nous cherchons ici une caractérisation exacte, à états finis, de la dynamique de chaque automate sous une distribution de données $P(X, Y)$ arbitraire – sans restreindre a priori la forme de cette distribution.

Propriété	TM	PCL	Notre règle
Dépend de la sortie de clause	Oui	Non	Non
Dépend du vote global	Oui	Non	Non
Paramètre par clause	(s, T)	p_k	(S, a)
Loi stationnaire finie explicite	Non	Non	Oui
Loi $P(X, Y)$ arbitraire	Non démontré	Non	Oui

3 Règle d'apprentissage locale à quatre cas

3.1 Cadre et notations

Soit $(X_t, Y_t)_{t \geq 1} \stackrel{\text{i.i.d.}}{\sim} P$ de loi jointe $P(X, Y)$ arbitraire, avec $X = (X_1, \dots, X_n) \in \{0, 1\}^n$ et $Y \in \{0, 1\}$. Pour chaque variable X_i , deux automates à $2N$ états gouvernent le littéral x_i et sa négation $\neg x_i$: v_i et $\bar{v}_i$, avec

$$\text{Include}(s) = \mathbf{1}[s > N], \quad s \in \{1, \dots, 2N\}.$$

La clause induite par ces automates est

$$C(x) = \bigwedge_{i: v_i > N} x_i \wedge \bigwedge_{i: \bar{v}_i > N} \neg x_i.$$

Les mouvements élémentaires d'un automate sont

$$s \xrightarrow{\text{Inc}} \min(s + 1, 2N), \quad s \xrightarrow{\text{Exc}} \max(s - 1, 1)$$

(bornes réfléchissantes : un automate déjà dans l'état $2N$ (resp. 1) reste sur place s'il reçoit à nouveau l'ordre Inc (resp. Exc) – d'où la chaîne de Markov naissance–mort *réfléchie* annoncée en Section 3.1).

3.2 Mise à jour à quatre cas

x_i	y	Action sur v_i	Action sur $\bar{v}_i$
0	0	vers Inc avec proba. S	vers Exc avec proba. S
0	1	vers Exc avec proba. a	pas de mise à jour
1	0	vers Exc avec proba. S	vers Inc avec proba. S
1	1	pas de mise à jour	vers Exc avec proba. a

avec $S, a \in (0, 1]$. Contrairement aux mécanismes de feedback des TM et de PCL, cette mise à jour ne dépend que de la paire locale (x_i, y) , et non de la sortie de la clause, du vote de l'ensemble, ou de l'état des autres automates.

3.3 Interprétation

Sur un exemple négatif ($y = 0$), la règle pousse chaque littéral vers l'état qui le rend *violé* par cet exemple (i.e. qui empêche la clause de répondre 1 à tort) : S contrôle la force de cet apprentissage. Sur un exemple positif ($y = 1$), la règle exclut les littéraux *incompatibles* avec cet exemple (ceux que l'exemple positif viole) : a contrôle la force de cette exclusion. À ce stade, rien ne garantit encore que la structure ainsi sélectionnée coïncide avec une éventuelle conjonction génératrice sous-jacente – ce point est traité séparément en Section 4.

3.4 Représentation graphique

La Table 1 (Section 3.2) reste la représentation formelle de référence. La Figure 1 n'en donne qu'une lecture graphique : la chaîne d'états d'un automate, avec la frontière Exclude/Include entre N et $N+1$.




Figure 1: Chaîne d'états d'un automate à $2N$ états. Les flèches représentent les mouvements Inc et Exc (Section 3.1) ; la frontière (pointillés) sépare Exclude ($1, \dots, N$) et Include ($N+1, \dots, 2N$).

3.5 Algorithme d'apprentissage local

```

Entrée : échantillons  $(x_t, y_t)$ ,  $2N$  états, paramètres  $S, a$ .
initialiser  $(v_i, \bar{v}_i)$  pour chaque feature  $i$ 
pour  $t = 1$  à  $T$  :
  pour  $i = 1$  à  $n$  :
    mettre à jour  $(v_i, \bar{v}_i)$  selon la Table 1, à partir de  $(x_{t,i}, y_t)$ 
  retourner la clause induite par les littéraux inclus

```

À ce stade, ni le boosting AdaBoost, ni les conditions aléatoires, ni le classifieur multiclasse ne sont encore introduits : ils font l'objet de la Section 5.

4 Analyse théorique

Cette section prouve la convergence de la règle locale à 4 cas elle-même, et non celle du classifieur complet ; son intégration dans un ensemble conditionné et boosté est traitée séparément en Section 5, comme une application dont l'analyse de convergence complète reste un travail futur.

4.1 Dynamique d'un automate isolé

Pour v_i , les probabilités de transition intérieures s'écrivent, pour toute loi P :

$$p_i^+ = S P(X_i=0, Y=0), \quad p_i^- = S P(X_i=1, Y=0) + a P(X_i=0, Y=1); \quad (1)$$

$$\bar{p}_i^+ = S P(X_i=1, Y=0), \quad \bar{p}_i^- = S P(X_i=0, Y=0) + a P(X_i=1, Y=1). \quad (2)$$

On note $\rho_i = p_i^+ / \bar{p}_i^-$, $\bar{\rho}_i = \bar{p}_i^+ / p_i^-$. Pour $p_i^+, p_i^- > 0$, chaque marginal $(v_{i,t})_t$ est une chaîne de Markov naissance–mort réfléchie sur $\{1, \dots, 2N\}$.

4.2 Loi stationnaire exacte

Théorème 1. *Soit $\rho = p^+ / p^-$, avec $p^+, p^- > 0$ (indices i omis). La chaîne (v_t) est irréductible et apériodique sur $\{1, \dots, 2N\}$, donc $\mathcal{L}(v_t) \xrightarrow[t \rightarrow \infty]{} \pi$ (convergence en loi vers l'unique loi stationnaire, théorème ergodique standard pour les chaînes de Markov finies irréductibles apériodiques), de loi stationnaire*

$$\pi(k) = \frac{(1-\rho)\rho^{k-1}}{1-\rho^{2N}} \quad (\rho \neq 1), \quad \pi(k) = \frac{1}{2N} \quad (\rho = 1), \quad \pi(\text{Inc}) = \frac{\rho^N}{1+\rho^N}.$$

Si $\rho > 1$: $\pi(\text{Inc}) \rightarrow 1$ et $1 - \pi(\text{Inc}) \leq \rho^{-N}$. Si $\rho < 1$: $\pi(\text{Exc}) \rightarrow 1$ symétriquement. De plus $\frac{1}{T} \sum_{t \leq T} \mathbf{1}[v_t > N] \rightarrow \pi(\text{Inc})$ p.s. Attention : ceci est une convergence en loi (stationnaire) et une convergence p.s. de la fréquence temporelle – pas une convergence p.s. de v_t vers un état fixe. Dans le cas ergodique ($p^+, p^- > 0$), l'automate continue de se déplacer indéfiniment ; il n'y a stabilisation permanente que dans le cas absorbant (Corollaire 2).

Proof. Irréductibilité. Chaîne de naissance-mort à transitions intérieures strictement positives.

Noyau explicite. Pour $2 \leq k \leq 2N-1$: $P(k, k+1) = p^+$, $P(k, k-1) = p^-$, $P(k, k) = 1 - p^+ - p^-$. Aux bornes réfléchissantes : $P(1, 1) = 1 - p^+$, $P(1, 2) = p^+$, $P(2N, 2N) = 1 - p^-$, $P(2N, 2N-1) = p^-$.

Apériodicité. $P(1, 1) = 1 - p^+ \geq p^- > 0$: l'état 1 a un cycle de longueur 1, donc une période $d(1) = 1$. Par irréductibilité, la période est une propriété de classe : toute la chaîne est apériodique.

Forme géométrique. Bilan détaillé $\pi(k)p^+ = \pi(k+1)p^-$ donne $\pi(k+1)/\pi(k) = \rho$ constant, soit $\pi(k) = \pi(1)\rho^{k-1}$; normalisation $\sum_{k=1}^{2N} \pi(k) = 1 = \pi(1) \sum_{k=0}^{2N-1} \rho^k$ donne $\pi(1) = (1-\rho)/(1-\rho^{2N})$ (série géométrique finie), d'où les formules annoncées. $\pi(\text{Inc}) = \sum_{k=N+1}^{2N} \pi(k) = \pi(1)\rho^N \sum_{k=0}^{N-1} \rho^k = \pi(1)\rho^N(1-\rho^N)/(1-\rho) = \rho^N(1-\rho^N)/(1-\rho^{2N}) = \rho^N/(1+\rho^N)$. La convergence p.s. de la moyenne temporelle est le théorème ergodique standard. $\square$

Corollaire 2 (Cas absorbant). Si $p^- = 0, p^+ > 0$: absorption p.s. en $2N$ en temps fini, $\mathbb{E}[T_{2N}] = (2N - s_0)/p^+$; première entrée dans Inc (franchissement de N), généralement plus rapide, $\mathbb{E}[T_{\text{Inc}}] = (N + 1 - s_0)_+/p^+$. Si $p^+ = 0, p^- > 0$: symétrique en $1/\text{Exc}$. Si $p^+ = p^- = 0$: aucune transition ne se produit jamais (chaque état trivialement absorbant), l'automate reste figé à s_0 .

4.3 Régimes de sélection des littéraux

Lemme 3. Soit $\Delta = p^+ - p^-$, $\bar{\Delta} = \bar{p}^+ - \bar{p}^-$. Pour toute loi $P(X, Y)$:

$$\Delta + \bar{\Delta} = -a P(Y=1) \leq 0.$$

Si $P(Y=1) > 0$, l'inégalité est stricte : $\Delta + \bar{\Delta} < 0$, donc $\Delta = \bar{\Delta} = 0$ simultanément est impossible. Si $P(Y=1) = 0$ (cas dégénéré), $\Delta + \bar{\Delta} = 0$ exactement.

Proof. De (1)–(2) : $\Delta = S P(0, 0) - S P(1, 0) - a P(0, 1)$, $\bar{\Delta} = S P(1, 0) - S P(0, 0) - a P(1, 1)$. La somme élimine les termes en S : $\Delta + \bar{\Delta} = -a[P(0, 1) + P(1, 1)] = -a P(Y=1) \leq 0$, avec égalité ssi $P(Y=1) = 0$ (puisque $a > 0$). $\square$

Corollaire 4. Si $\Delta > 0$ alors $\bar{\Delta} = -a P(Y=1) - \Delta < 0$ strictement.

Remarque 5. Le lemme exclut $\Delta > 0$ et $\bar{\Delta} > 0$ simultanément ; il n'exclut pas $\Delta < 0$ et $\bar{\Delta} < 0$ simultanément (double exclusion, régime neutre). Pour N fini et $\rho \neq 1$, l'état instantané peut néanmoins se trouver du mauvais côté avec probabilité $\leq \rho^{-N} \rightarrow 0$.

Théorème 6. Supposons $\Delta \neq 0$ et $\bar{\Delta} \neq 0$. Notons $\gamma = \max(\rho, 1/\rho) > 1$, $\bar{\gamma} = \max(\bar{\rho}, 1/\bar{\rho}) > 1$ (probabilité du mauvais côté toujours $\leq \gamma^{-N}$, resp. $\bar{\gamma}^{-N}$, quel que soit le signe de $\Delta, \bar{\Delta}$). Alors exactement un des trois régimes suivants a lieu :

- $\Delta > 0$ (donc $\bar{\Delta} < 0$) $\iff S P(0, 0) > S P(1, 0) + a P(0, 1)$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc})) = 0.$$

- $\bar{\Delta} > 0$ (donc $\Delta < 0$) $\iff S P(1, 0) > S P(0, 0) + a P(1, 1)$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Inc})) = 0.$$

- $\Delta < 0$ et $\bar{\Delta} < 0$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Exc})) = 0.$$

Proof. Les équivalences découlent de (1)–(2). L'exclusion mutuelle des trois régimes découle du Corollaire 4. Passage du marginal au joint (cas $\Delta > 0$: $\rho > 1$ donc $\gamma = \rho$, $\bar{\rho} < 1$ donc $\bar{\gamma} = 1/\bar{\rho}$; similaire ailleurs), sans invoquer de loi stationnaire jointe (la chaîne $(v_t, \bar{v}_t)$ n'est pas nécessairement irréductible – ex. $S=1$, $P(Y=1)=0$ conserve $v_t + \bar{v}_t$). En prenant d'abord $\limsup_{t \rightarrow \infty}$ (la borne du Théorème 1 porte sur la loi stationnaire, atteinte seulement asymptotiquement en t – fausse pour un t petit et une initialisation arbitraire), puis par union bound,

$$\limsup_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc})) \leq \limsup_{t \rightarrow \infty} \mathbb{P}(v_t \neq \text{Inc}) + \limsup_{t \rightarrow \infty} \mathbb{P}(\bar{v}_t \neq \text{Exc}) \leq \gamma^{-N} + \bar{\gamma}^{-N},$$

sans hypothèse d'indépendance entre v_t et $\bar{v}_t$. Puis $\gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow{N \rightarrow \infty} 0$ donne la double limite annoncée. Noter $\bar{\gamma}^{-N} = \bar{\rho}^N$ ici (pas $\bar{\rho}^{-N}$, puisque $\bar{\rho} < 1$) : c'est pour éviter cette confusion de signe que $\gamma = \max(\rho, 1/\rho)$ est défini une fois pour toutes. $\square$




Figure 2: Validation empirique du Théorème 6 : pour une paire $(v, \bar{v})$ sous une loi $P(X, Y)$ fixée ($\Delta > 0$), probabilité $P((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc}))$ en fonction de N , comparée à la borne exacte $\gamma^{-N} + \bar{\gamma}^{-N}$. Simulation fidèle à la règle réelle : un seul exemple (x, y) tiré par pas de temps (partagé par v et $\bar{v}$, comme dans le code), chaque automate concerné appliquant ensuite son propre tirage indépendant – v et $\bar{v}$ ne sont donc pas simulés comme des marches indépendantes. Nombre de répétitions adapté à chaque N pour garder au moins ~ 20 évènements « mauvais régime » observés ; la courbe empirique reste sous la borne sur toute la plage $N=2$ à 20 (à $N=24$, 0 évènement observé sur 25 000 répétitions, cohérent avec une borne de l'ordre de 8×10^{-9}).

4.4 Concentration structurelle multi-features

Théorème 7. *Clause à n features, K fixées par la condition, $d = n - K$ libres gouvernées par $2d$ automates. Pour chaque automate j (préférence stationnaire non dégénérée), $r_j = p_j^+ / p_j^-$, $\gamma_j = \max(r_j, 1/r_j) > 1$, $\gamma_{\min} = \min_j \gamma_j$. Alors, sans hypothèse d'indépendance, l'erreur de récupération structurelle vérifie :*

$$\limsup_{t \rightarrow \infty} \mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \frac{1}{1 + \gamma_j^N} \leq 2(n - K) \gamma_{\min}^{-N} \xrightarrow{N \rightarrow \infty} 0.$$

Proof. Soit A_j l'évènement « l'automate j est du mauvais côté ». Si tous les A_j sont faux, chaque automate est dans son état préféré, donc $C_t = C^*$; par contraposée, $\{C_t \neq C^*\} \subseteq A_1 \cup \dots \cup A_{2d}$, d'où par l'union bound (Boole) :

$$\mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \mathbb{P}(A_j).$$

Par le Théorème 1, $\mathbb{P}(A_j) = \pi(\text{Exc}) = 1/(1 + r_j^N)$ si $r_j > 1$, ou $\pi(\text{Inc}) = r_j^N/(1 + r_j^N)$ si $r_j < 1$ – dans les deux cas exactement $1/(1 + \gamma_j^N)$, d'où la première inégalité. Ensuite, $1/(1 + \gamma_j^N) < \gamma_j^{-N}$ (dénominateur plus grand), et $\gamma_j \geq \gamma_{\min}$ donne $\gamma_j^{-N} \leq \gamma_{\min}^{-N}$; en remplaçant chacun des $2d$ termes par cette même borne on obtient $2(n - K) \gamma_{\min}^{-N}$. $\square$

Remarque 8. Cas $r_j = 1$ et $p_j^+ = p_j^- = 0$ exclus (non-dégénérescence) ; automate absorbant (Corollaire 2) couvert par $\gamma_j = \infty$. La borne utilise le pire automate, pas le meilleur. $C_t \neq C^*$ est un mismatch structurel (deux structures différentes peuvent calculer la même fonction logique par coïncidence), pas nécessairement une erreur de classification.




Figure 3: Validation empirique du Théorème 7 : erreur de récupération structurelle $P(C_t \neq C^*)$ en fonction de N , pour une clause à 3 features de difficultés différentes ($\gamma_{\min} \approx 1.17$). Simulation fidèle à la règle réelle : un seul exemple (x_1, x_2, x_3, y) tiré par pas de temps (loi jointe à indépendance conditionnelle en Y), chacun des 6 automates étant mis à jour à partir de ce même tirage partagé – pas $2d$ marches indépendantes. L'empirique reste toujours sous la borne théorique sur toute la plage $N=2$ à 40.

4.5 Récupération d'une conjonction cible

Le Théorème 6 caractérise la structure préférée sous une loi P arbitraire, mais ne dit pas si cette structure est la véritable cible. On le montre ici pour une famille explicite de concepts : une conjonction cible, sous une loi jointe $(X_1, \dots, X_n, Y)$ *quelconque* (features corrélées, déséquilibrées, dépendantes) telle que $Y = Y^*$.

Définition 9. Soit $C_{\text{true}}(x) = \bigwedge_{j \in J_+} x_j \wedge \bigwedge_{j \in J_-} (1 - x_j)$ une conjonction de $m = |J_+| + |J_-| \geq 1$ littéraux, $J_+ \cap J_- = \emptyset$ – une fonction booléenne fixe, déterministe. On pose $Y^* = C_{\text{true}}(X)$, la variable aléatoire obtenue en évaluant cette fonction sur X .

Théorème 10 (Identification sous dépendance de features arbitraire). Avec C_{true}, Y^* comme dans la Définition 9, supposons seulement $Y = Y^*$ (p.s.) – la loi jointe de $(X_1, \dots, X_n)$ est *quelconque* (dépendante, déséquilibrée). Pour chaque variable j , notons

$$A_j = P(X_j=0, Y=0), \quad B_j = P(X_j=1, Y=0), \quad C_j = P(X_j=0, Y=1), \quad D_j = P(X_j=1, Y=1).$$

Alors :

- pour $j \in J_+$: si $A_j > B_j$, alors $\Delta_j > 0$ et $\bar{\Delta}_j < 0$;

- pour $j \in J_-$: si $B_j > A_j$, alors $\bar{\Delta}_j > 0$ et $\Delta_j < 0$;
- pour $k \notin J_+ \cup J_-$: si $-a D_k < A_k - B_k < \frac{a}{S} C_k$, alors $\Delta_k < 0$ et $\bar{\Delta}_k < 0$.

Si ces conditions sont vérifiées pour tous les littéraux concernés, alors $C^* = C_{\text{true}}$ (égalité structurelle : C^* et C_{true} désignent la même fonction booléenne, encodée par le même ensemble de littéraux).

Proof. Pour $j \in J_+$: $Y=1 \Rightarrow X_j=1$, donc $C_j = P(X_j=0, Y=1) = 0$, et par (1) : $\Delta_j = S A_j - S B_j - a \cdot 0 = S(A_j - B_j)$, positif ssi $A_j > B_j$. Par le Lemme 3, $\bar{\Delta}_j = -a P(Y=1) - \Delta_j$; comme $a \geq 0$ et $P(Y=1) \geq 0$, $\Delta_j > 0 \Rightarrow \bar{\Delta}_j \leq -\Delta_j < 0$. Symétriquement pour $j \in J_-$: $Y=1 \Rightarrow X_j=0$ donne $D_j = P(X_j=1, Y=1) = 0$, d'où par (2) : $\bar{\Delta}_j = S B_j - S A_j - a \cdot 0 = S(B_j - A_j)$, positif ssi $B_j > A_j$, et alors $\Delta_j = -a P(Y=1) - \bar{\Delta}_j < 0$.

Pour k non pertinent, (1)–(2) donnent $\Delta_k = S(A_k - B_k) - a C_k$ et $\bar{\Delta}_k = S(B_k - A_k) - a D_k$ (sans simplification possible ici, C_k, D_k quelconques). $\Delta_k < 0 \iff A_k - B_k < \frac{a}{S} C_k$; $\bar{\Delta}_k < 0 \iff A_k - B_k > -\frac{a}{S} D_k$. Les deux réunies donnent l'encadrement annoncé. $\square$

Remarque 11. Le Théorème 10 ne suppose ni indépendance ni équilibre des features : A_j, B_j, C_j, D_j sont des probabilités jointes quelconques et les conditions ($A_j > B_j$, etc.) portent sur n'importe quelle loi jointe, pas sur un modèle génératif particulier.

Théorème 12 (Robustesse à un bruit de label dépendant de la distribution). Reprenons les notations et hypothèses du Théorème 10, et notons $\Delta_j^*, \bar{\Delta}_j^*, \Delta_k^*, \bar{\Delta}_k^*$ les dérivées calculées avec le label sans bruit Y^* . Définissons

$$\mu = \min \left(\{ \Delta_j^* : j \in J_+ \} \cup \{ -\bar{\Delta}_j^* : j \in J_+ \} \cup \{ -\Delta_j^* : j \in J_- \} \cup \{ \bar{\Delta}_j^* : j \in J_- \} \cup \right. \\ \left. \{ -\Delta_k^* : k \notin J_+ \cup J_- \} \cup \{ -\bar{\Delta}_k^* : k \notin J_+ \cup J_- \} \right),$$

c'est-à-dire le plus petit des membres de gauche de toutes les inégalités strictes exigées par le Théorème 10 (une quantité par littéral et par signe requis) ; supposons $\mu > 0$, i.e. ces inégalités sont toutes satisfaites sans bruit. Soit maintenant Y un label tel que $\eta := P(Y \neq Y^*) > 0$, sans aucune autre hypothèse sur la loi du bruit $Y \neq Y^*$ (ni symétrie, ni indépendance vis-à-vis de X). Si

$$\boxed{\eta < \frac{\mu}{S + a}},$$

alors toutes les inégalités du Théorème 10 restent satisfaites (avec Y à la place de Y^*) et $C^* = C_{\text{true}}$. Combiné au Théorème 7, ceci donne directement $\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}(C_t \neq C_{\text{true}}) = 0$: la règle récupère, avec probabilité tendant vers 1, la conjonction génératrice exacte – pas seulement une structure définie implicitement par P – tant que le bruit reste sous ce seuil.

Proof. Étape 1 : chaque dérive est une espérance. Par (1), $\Delta_j = S P(X_j=0, Y=0) - S P(X_j=1, Y=0) - a P(X_j=0, Y=1)$. Ceci s'écrit $\Delta_j = \mathbb{E}[c(X_j, Y)]$ où $c : \{0, 1\}^2 \rightarrow \mathbb{R}$ est définie par $c(0, 0) = S$, $c(1, 0) = -S$, $c(0, 1) = -a$, $c(1, 1) = 0$. De même, par (2), $\bar{\Delta}_j = \mathbb{E}[\bar{c}(X_j, Y)]$ avec $\bar{c}(1, 0) = S$, $\bar{c}(0, 0) = -S$, $\bar{c}(1, 1) = -a$, $\bar{c}(0, 1) = 0$ (les rôles

de $Y=0$ et $Y=1$ sont échangés par rapport à c). Notons $\Delta_j^* = \mathbb{E}[c(X_j, Y^*)]$ la même quantité calculée avec Y^* au lieu de Y .

Étape 2 : un couplage naturel. Puisque X suit la même loi dans les deux cas (seul le label diffère), couplons Y et Y^* sur le même espace de probabilité que X , de sorte que $\{Y \neq Y^*\}$ soit exactement l'événement de bruit, de probabilité η . Un tel couplage existe toujours (c'est la définition même de « Y est un label bruité de Y^* avec taux η »). Alors

$$\Delta_j - \Delta_j^* = \mathbb{E}[c(X_j, Y) - c(X_j, Y^*)] = \mathbb{E}\left[\left(c(X_j, Y) - c(X_j, Y^*)\right)\mathbf{1}[Y \neq Y^*]\right],$$

la dernière égalité car le terme entre crochets est nul dès que $Y = Y^*$.

Étape 3 : borne ponctuelle du saut de c , à X_j fixé. Sur l'événement $Y \neq Y^*$, les deux valeurs Y, Y^* sont distinctes dans $\{0, 1\}$, donc $\{Y, Y^*\} = \{0, 1\}$ dans un ordre ou l'autre. Fixons la valeur de X_j :

- si $X_j = 0$: les deux valeurs possibles de $c(0, \cdot)$ sont $c(0, 0) = S$ et $c(0, 1) = -a$, donc $|c(0, Y) - c(0, Y^*)| = |S - (-a)| = S + a$;
- si $X_j = 1$: les deux valeurs possibles sont $c(1, 0) = -S$ et $c(1, 1) = 0$, donc $|c(1, Y) - c(1, Y^*)| = |-S - 0| = S$.

Dans les deux cas, $|c(X_j, Y) - c(X_j, Y^*)| \leq S + a$ (le maximum, $S + a$, est atteint en $X_j = 0$; puisque $a > 0$, il domine S). Cette borne est *ponctuelle* : elle vaut pour toute réalisation de X_j , pas seulement en moyenne.

Étape 4 : passage à l'espérance. En combinant les étapes 2 et 3,

$$|\Delta_j - \Delta_j^*| \leq \mathbb{E}\left[|c(X_j, Y) - c(X_j, Y^*)| \mathbf{1}[Y \neq Y^*]\right] \leq (S + a) \mathbb{E}[\mathbf{1}[Y \neq Y^*]] = (S + a) \eta.$$

Le même raisonnement appliqué à $\bar{c}$ (saut $S + a$ atteint en $X_j = 1$ cette fois, par symétrie des rôles de 0, 1 sur Y) donne $|\bar{\Delta}_j - \bar{\Delta}_j^*| \leq (S + a)\eta$. Le même argument, avec exactement les mêmes fonctions $c, \bar{c}$, s'applique aux variables non pertinentes k et donne $|\Delta_k - \Delta_k^*| \leq (S + a)\eta$, $|\bar{\Delta}_k - \bar{\Delta}_k^*| \leq (S + a)\eta$.

Étape 5 : préservation des signes. Soit $\eta < \mu/(S + a)$, i.e. $(S + a)\eta < \mu$. Prenons par exemple $j \in J_+$: par définition de μ , $\Delta_j^* \geq \mu$. Par l'étape 4, $\Delta_j \geq \Delta_j^* - (S + a)\eta \geq \mu - (S + a)\eta > 0$ puisque $(S + a)\eta < \mu$. De même $-\bar{\Delta}_j^* \geq \mu$ donne $\bar{\Delta}_j \leq \bar{\Delta}_j^* + (S + a)\eta \leq -\mu + (S + a)\eta < 0$. Le même calcul, terme à terme, s'applique à $j \in J_-$ et aux k non pertinents. Donc toutes les inégalités strictes du Théorème 10 restent vraies avec Y à la place de Y^* , ce qui conclut. $\square$

5 Ensemble conditionné et boosté

On intègre la règle à 4 cas dans un ensemble conditionné (conditions aléatoires) et boosté (AdaBoost) pour illustrer son utilité pratique en classification. **L'analyse de convergence complète de cet ensemble – couverture des conditions sous la distribution adaptative Q_m , et convergence du vote pondéré final – n'est pas prouvée ici et reste un travail futur.** Les résultats de cette section (couverture, boosting) caractérisent des propriétés partielles utiles mais ne ferment pas cette boucle.




Figure 4: Validation empirique du Théorème 12 : taux de récupération exacte de C_{true} ($n=6$, $m=3$, $S=1$, $a=0.3$) en fonction du bruit de label η , sur 200 répétitions par point. La transition empirique se produit nettement autour du seuil exact $\eta^*=2S/(4S+a \cdot 2^m)=0.3125$, calculé directement pour ce cas i.i.d. Bernoulli(1/2) – la borne générale du Théorème 12, $\mu/(S+a) \approx 0.014$, est confirmée très conservatrice pour ce cas particulier.

5.1 Conditions aléatoires

Pour chaque clause m , on tire une condition $F_m \subseteq \{1, \dots, n\}$, $|F_m| = K$, et une configuration $z_m \in \{0, 1\}^K$, uniformément indépendamment. La clause n'est active que sur les exemples qui satisfont sa condition :

$$g_m(x) = \mathbf{1}[x_{F_m} = z_m].$$

Les variables de F_m sont retirées de l'apprentissage local : leurs deux automates (v_i et $\bar{v}_i$ pour $i \in F_m$) sont fixés dans l'état Exclude et ne sont plus mis à jour – la condition $x_{F_m} = z_m$ elle-même n'est pas encodée par des littéraux inclus dans la clause, mais imposée séparément par le mécanisme d'activation g_m . Seules les $n - K$ variables restantes sont gouvernées par $2(n - K)$ automates entraînaables par la règle à quatre cas.

5.2 Entraînement de la clause

Pour chaque clause m : (1) on sélectionne le sous-ensemble S_m des exemples d'entraînement satisfaisant g_m ; (2) on équilibre le tirage 50/50 entre les deux classes lorsque les deux sont présentes dans S_m ; (3) au sein de chaque classe, le tirage est proportionnel aux poids AdaBoost courants w_i ; (4) chaque exemple ainsi tiré met à jour les $n - K$ automates libres par la règle à quatre cas.

5.3 Agrégation pondérée

Pour un classifieur binaire :

$$f(x) = \sum_{m=1}^M \alpha_m g_m(x) (2C_m(x) - 1), \quad \hat{y} = \mathbf{1}[f(x) > 0],$$

avec

$$\alpha_m = \frac{1}{2} \ln \frac{1 - \text{err}_m}{\text{err}_m}.$$

Chaque weak learner $h_m(x) = g_m(x)(2C_m(x) - 1) \in \{-1, 0, 1\}$ s'abstient (valeur 0) lorsque sa condition n'est pas satisfaite par x : il s'agit donc d'un *AdaBoost avec abstention*, où α_m et la mise à jour des poids ne portent que sur la masse active S_m , et non d'AdaBoost standard appliqué tel quel à un classifieur binaire toujours actif.

5.4 Caractérisation par round de boosting

Les Théorèmes 1, 6, 7, 10, 12 portent sur une clause unique sous une loi $P(X, Y)$ fixe. Le classifieur de la Section 5 entraîne chaque clause m sous une distribution adaptative Q_m qui change à chaque round de boosting – ce résultat précise exactement ce qui, dans cet écart, est couvert et ce qui ne l'est pas.

Théorème 13 (Distribution d'entraînement effective d'un round). *Soit S_m le sous-ensemble applicable de la clause m (exemples satisfaisant g_m) et w_i les poids AdaBoost courants sur S_m . Notons $W_m^+ = \sum_{i \in S_m: y_i=1} w_i$, $W_m^- = \sum_{i \in S_m: y_i=0} w_i$. L'Algorithme de la Section 5.6 ne tire pas directement selon la distribution pondérée $D_m(i) = w_i / \sum_{j \in S_m} w_j$: il choisit d'abord la classe positive ou négative avec probabilité $\frac{1}{2}$ chacune si les deux sont présentes dans S_m , sinon il échantillonne exclusivement dans l'unique classe présente. La distribution effectivement échantillonnée pour mettre à jour les automates de la clause m est donc*

$$Q_m(i) = \begin{cases} \frac{1}{2} w_i / W_m^+, & i \in S_m, y_i=1, W_m^+, W_m^- > 0, \\ \frac{1}{2} w_i / W_m^-, & i \in S_m, y_i=0, W_m^+, W_m^- > 0, \\ w_i / W_m^+, & i \in S_m, y_i=1, W_m^- = 0, \\ w_i / W_m^-, & i \in S_m, y_i=0, W_m^+ = 0, \\ 0, & i \notin S_m. \end{cases}$$

Conditionnellement à l'historique du boosting et au tirage aléatoire de la condition (F_m, z_m) du round m , et sur l'évènement $S_m \neq \emptyset$, les Théorèmes 1, 6, 7, 10, 12 s'appliquent tels quels à la clause m , chacun sous ses hypothèses respectives, avec $P(X, Y)$ remplacée par $Q_m(X, Y)$ – et non par D_m .

Proof. Les probabilités de transition (1)–(2) sont des fonctions linéaires de la loi utilisée pour générer les tirages effectivement présentés à l'automate ; elles ne supposent jamais une forme particulière de cette loi, donc substituer Q_m à P ne change aucune étape des preuves précédentes. Q_m , et non D_m , est la loi qui génère les (x, y) réellement vus par la mise à jour de la clause m (tirage 50/50 puis proportionnel à w , Section 5.2) ; D_m n'intervient que dans le calcul de l'erreur pondérée et de α_m (Section 5.3). $\square$

Remarque 14 (Ce que ce théorème ne prouve pas). *Il caractérise chaque round isolément, conditionnellement à Q_m – il ne prouve pas la convergence du vote pondéré final $f_c(x) = \sum_m \alpha_{c,m} h_{c,m}(x)$ vers un classifieur de Bayes global (ce qu’AdaBoost classique établit sous des hypothèses différentes, non reprises ici), ni que la structure identifiée round après round reste stable ou cohérente d’un round à l’autre. Nous ne revendiquons pas ce résultat plus fort : c’est précisément l’écart entre théorie de la règle locale et convergence de l’ensemble complet annoncé en introduction et en conclusion.*

5.5 Extension multiclasse

Pour chaque classe c , on pose $Y^{(c)} = \mathbf{1}[Y=c]$ et on entraîne un ensemble indépendant de clauses conditionnées et boostées pour ce problème binaire :

$$f_c(x) = \sum_{m=1}^M \alpha_{c,m} g_{c,m}(x) (2 C_{c,m}(x) - 1), \quad \hat{y} = \arg \max_c f_c(x).$$

5.6 Algorithme complet

Entrée : dataset $\{(x_i, y_i)\}$, n features, N états, M clauses, K features gelées/clause, $total$ tirages/clause, S, a .

$w_i \leftarrow 1/|train|$ pour tout i

pour $m = 1$ à M :

 tirer $F \subseteq \{1, \dots, n\}$, $|F| = K$, uniformément (shuffle)

 tirer $v \in \{0, 1\}^K$ uniformément (pile-ou-face indépendant/feature)

 créer une clause C_m conditionnée sur (F, v) ; geler ces K littéraux

$S_m \leftarrow \{i : (x_i)_F = v\}$

si $S_m = \emptyset$: $\alpha_m \leftarrow 0$; **continuer**

pour $t = 1$ à $total$:

 tirer $i \in S_m$ selon Q_m (50/50 classe, puis $\propto w_i$ dans la classe)

 mettre à jour C_m avec $(x_i, \mathbf{1}[y_i=c])$ (règle à 4 cas)

si C_m vide (aucun littéral inclus) : $\alpha_m \leftarrow 0$; **continuer** (pas

de mise à jour des poids)

$err_m \leftarrow \sum_{i \in S_m} w_i \mathbf{1}[C_m(x_i) \neq \mathbf{1}[y_i=c]] / \sum_{i \in S_m} w_i$ (sous D_m)

$err_m \leftarrow \text{clip}(err_m, \epsilon, 1 - \epsilon)$

$\alpha_m \leftarrow \frac{1}{2} \ln((1 - err_m)/err_m)$

pour $i \in S_m$: $w_i \leftarrow w_i \cdot \exp(\pm \alpha_m)$ (signe + si erreur, – sinon)

 renormaliser w sur tout le dataset

retourner $(C_1, \dots, C_M), (\alpha_1, \dots, \alpha_M)$

Prédiction. Pour x et chaque classe c :

$$\text{score}_c(x) = \sum_{m=1}^M \alpha_{c,m} \cdot (2 C_{c,m}(x) - 1) \cdot \mathbf{1}[(x)_{F_{c,m}} = v_{c,m}] \cdot \mathbf{1}[C_{c,m} \text{ non vide}],$$

puis $\hat{y} = \arg \max_c \text{score}_c(x)$ (clause ignorée si sa condition n’est pas satisfaite par x ou si elle est vide).

5.7 Complexité

Pour une classe donnée : la construction des sous-ensembles S_m (tester, pour chacun des N_{train} exemples et chacune des M clauses, si sa condition à K features est satisfaite)

coûte $O(M N_{\text{train}} K)$; l’entraînement proprement dit coûte ensuite $O(M \cdot \text{total} \cdot (n - K))$ (chacune des M clauses reçoit *total* tirages, chacun mettant à jour les $n - K$ automates libres – les K automates gelés ne sont jamais touchés). La mémoire est en $O(Mn)$ (deux automates par feature et par clause). La prédiction sur un exemple coûte $O(Mn)$ dans le pire cas, mais en pratique beaucoup moins : tester la condition de chacune des M clauses coûte $O(MK)$, et une condition à K features tirée uniformément n’est satisfaite que par une fraction $\approx 2^{-K}$ des exemples en espérance, de sorte que le nombre *attendu* de clauses dont on évalue ensuite la conjonction (coût $O(n - K)$ chacune) est $\approx M \cdot 2^{-K}$. Le coût moyen de prédiction est donc

$$O(MK + M \cdot 2^{-K} \cdot (n - K)).$$

6 Validation empirique

Comparaison de notre modèle à la Tsetlin Machine officielle (`pyTsetlinMachine`, configurations publiées) et à cinq baselines classiques (`scikit-learn`, hyperparamètres par défaut). Tous les modèles sont évalués sur les mêmes fichiers de données et, quand un remélange est nécessaire, la même seed par run (20000 + run). Écart-type rapporté : $\sqrt{\frac{1}{R} \sum_r (\text{acc}_r - \text{acc})^2}$ (écart-type empirique de population, $1/R$, pas l’estimateur non biaisé $1/(R-1)$). **Budgets non égalisés** entre notre modèle et la TM (nombre de clauses différent par dataset, cf. ci-dessous, et même à nombre de clauses égal – cf. MNIST – le nombre de mises à jour par clause (*total*) diffère du nombre d’epochs de la TM, donc le budget de calcul proprement dit reste distinct) : ces comparaisons ne sont donc pas équitables en termes de calcul. PCL (AAAI-25, related work le plus proche) n’est pas comparé systématiquement sur XOR/Digits/MNIST : PCL s’effondre sur XOR bruité avec ses hyperparamètres publiés (toutes les clauses restent vides), et son propre article ne l’évalue lui-même que sur la récupération de conjonctions synthétiques et sur Iris binaire – pas sur des jeux multiclassés larges. Nous le comparons donc directement là où la comparaison est protocolairement fondée (Section 6.1 ci-dessous), en réutilisant le code officiel de PCL.

6.1 Comparaison directe à PCL

En reprenant le protocole exact de l’article PCL (code officiel, `dpcl-classifier/Main_code_AAAI25`), deux comparaisons directes :

Récupération d’une conjonction cible. Protocole et paramètres par défaut du code officiel de PCL, inchangés : cible C_{true} tirée aléatoirement (chaque littéral indépendamment positif, négatif ou absent, un littéral au moins forcé présent), table de vérité complète (2^n exemples, ordre fixe, sans remélange), 100 epochs (soit $100 \cdot 2^n$ mises à jour), 100 runs, une seule clause, $N=10\,000$ états pour les deux méthodes, automates initialisés adjacents à la frontière Include/Exclude (N ou $N+1$). PCL : $p=0.75$ (défaut de leur code). Notre règle : $S=1.0$, $a=0.3$. Succès = littéraux appris exactement égaux aux littéraux cibles.

n	4	6	8	10	12
PCL	99/100	80/100	57/100	47/100	37/100
Notre règle	100/100	100/100	100/100	100/100	100/100

Ce protocole balaie la table de vérité dans un ordre fixe répété sur 100 epochs – une séquence déterministe périodique, pas un tirage i.i.d. de (X_t, Y_t) au sens du Théorème 10 ; sans bruit, ce balayage complet représente néanmoins exactement la loi $P(X, Y)$ dégénérée voulue (chaque combinaison de X avec sa vraie étiquette, sans distorsion), donc le résultat reste une validation directe et fidèle du théorème sur ce cas limite. Notre règle récupère la cible exactement sur les 100 cibles testées à chaque n (aucun échec observé, ce qui ne garantit pas une probabilité de succès exactement égale à 1), là où PCL se dégrade avec n .

Iris binaire. Classe versicolor contre les deux autres, 16 features binaires, split 70/30 aléatoire, $p_i \sim U(0.6, 0.8)$ par clause pour PCL (16 clauses, 100 epochs) – protocole et données de l’article PCL.

Méthode	Précision
PCL (code officiel, 92.4% publié)	92.22% $\pm$ 3.80%
Notre méthode complète ($M=300$, $K=2$, $total=2000$)	93.60% $\pm$ 3.63%

Notre reproduction de PCL (92.22%) est cohérente avec leur chiffre publié (92.4%), validant le protocole. Les deux intervalles (± 1 écart-type) se recouvrent largement et M diffère (300 clauses contre 16) : notre méthode complète est *compétitive* avec PCL sur son propre protocole Iris, sans qu’on puisse affirmer une supériorité statistiquement significative sur cette seule expérience. Sur données réelles bruitées, la règle seule (sans conditions ni boosting) dégénère en revanche nettement – privée de tout mécanisme de diversité entre clauses, elle converge vers une structure unique répétée M fois ; c’est l’ensemble conditionné et boosté complet (Section 5), et non la règle isolée, qui doit être comparé à PCL sur ce type de données.

6.2 Ablation : conditions et boosting

Sur XOR bruité (configuration de la Section 6.3 : $M=200$, $K=1$, $S=1.0$, $a=0.35$, $N=50$, $total=5000$), on active/désactive indépendamment les conditions aléatoires et le boosting AdaBoost, à hyperparamètres fixes (10 runs) :

Variante	Précision
A. Règle seule (sans conditions, sans boosting)	48.86% $\pm$ 0.00%
B. + conditions seules (sans boosting)	100.00% $\pm$ 0.00%
C. + boosting seul (sans conditions)	48.86% $\pm$ 0.00%
D. Modèle complet (conditions + boosting)	100.00% $\pm$ 0.00%

Les variantes A et C sont numériquement identiques : sans conditions, $S=1.0$ rend la mise à jour déterministe sur la branche dominante (les exemples négatifs, majoritaires), si bien que toutes les clauses convergent vers la même structure quels que soient les poids AdaBoost – le rééquilibrage des poids ne peut pas créer de diversité entre des clauses qui ignorent ces poids. Sur ce problème, **l’expressivité provient du conditionnement aléatoire, pas du boosting** : geler une variable rend la seconde localement informative sur chaque sous-ensemble conditionné (un mécanisme cohérent avec le Théorème 6, mais dont la contribution exacte à l’expressivité de l’ensemble n’est pas analysée formellement, cf. Théorème 13). Le boosting n’ajoute rien ici au-delà des conditions ($B = D$) ; son rôle – pondérer et filtrer les clauses faibles à plus

grande échelle – est plausiblement plus utile sur des problèmes multiclassés (Digits, MNIST) que sur XOR, mais cela n’est pas testé ici.

6.3 XOR

Fichiers fixes (`NoisyXORTrainingData.txt/TestData.txt`, 5000/5000), aucun remélange. Notre modèle : $M=200$, $K=1$, $S=1.0$, $a=0.35$, $N=50$, $total=5000$. TM : 20 clauses, $T=15$, $s=3.9$, 200 epochs. 20 runs partout.

Modèle	Précision
Notre modèle	100% $\pm$ 0%
Tsetlin Machine (officielle)	97.40% $\pm$ 2.23%
SVM	98.12% $\pm$ 0%
MLP	76.72% $\pm$ 1.97%
Random Forest	66.52% $\pm$ 0.30%
Régression logistique	48.94% $\pm$ 0%
Naive Bayes	49.12% $\pm$ 0%

6.4 Iris

Fichier unique (`BinaryIrisData.txt`, 149 exemples), remélange 80/20 à chaque run. Notre modèle : $M=1500$, $K=2$, $S=1.0$, $a=0.3$, $N=100$, $total=20000$. TM : 300 clauses, $T=10$, $s=3.0$, 500 epochs. 20 runs partout.

Modèle	Précision
Notre modèle	95.5% $\pm$ 4.25%
Random Forest	95.33% $\pm$ 3.86%
MLP	94.50% $\pm$ 3.38%
Tsetlin Machine (officielle)	93.50% $\pm$ 4.28%
SVM	92.67% $\pm$ 4.03%
Régression logistique	92.50% $\pm$ 4.70%
Naive Bayes	90.67% $\pm$ 4.29%

Notre modèle et Random Forest sont dans la marge de bruit l’un de l’autre.

6.5 Digits

Fichiers fixes (`BinaryDigitsTrainingData192.txt/TestData192.txt`, 1437/360), aucun remélange. Notre modèle : $M=2000$, $K=2$, $S=0.05$, $a=1.0$, $N=100$, $total=20000$. TM : 1000 clauses, $T=10$, $s=3.0$, 300 epochs. 10 runs partout.

Modèle	Précision
Notre modèle	97.19% $\pm$ 0.40%
SVM	97.50% $\pm$ 0%
Random Forest	97.31% $\pm$ 0.31%
MLP	97.17% $\pm$ 0.41%
Régression logistique	96.11% $\pm$ 0%
Tsetlin Machine (officielle)	93.69% $\pm$ 0.76%
Naive Bayes	91.39% $\pm$ 0%

6.6 MNIST

Fichiers fixes (MNISTTraining.txt/Test.txt, 60000/10000), aucun remélange. Notre modèle : $M=16000$, $K=2$, $S=1.0$, $a=0.3$, $N=100$, $total=20000$. TM : 4000 clauses/classe, $T=50$, $s=10.0$, 20 epochs.

Modèle	Précision
SVM	97.71% $\pm$ 0%
Random Forest	97.07% $\pm$ 0.06%
MLP	96.90% $\pm$ 1.03%
Tsetlin Machine (officielle, 4000 clauses/classe)	96.62% $\pm$ 0.07% (3 runs)
Notre modèle ($M=16000$ /classe)	95.85% (1 run)
Régression logistique	91.89% $\pm$ 0%
Notre modèle ($M=4000$ /classe, nombre de clauses égal à la TM)	93.56% (1 run)
Naive Bayes	84.23% $\pm$ 0%

6.7 Effet de M sur la précision

Sur XOR (config. Section 6.1 fixée, M variable, 20 runs/point) :

M	5	10	20	50	100	200	400
Précision	64.9%	75.1%	84.7%	96.8%	99.3%	100%	100%

Rendements décroissants nets, saturés dès $M=200$ (configuration retenue en Section 6.1).

7 Limites et conclusion

Ce qui est prouvé. La règle locale à quatre cas admet une loi stationnaire exacte sous toute loi $P(X, Y)$ (Théorème 1), ne peut pas favoriser stationnairement l'inclusion simultanée d'un littéral et de sa négation (Lemme 3 – à N fini, l'état instantané peut néanmoins se trouver transitoirement du mauvais côté, avec probabilité $\leq \rho^{-N} \rightarrow 0$), présente exactement l'un de trois régimes de préférence stationnaire déterminés par le signe de $\Delta, \bar{\Delta}$ (Théorème 6), et concentre, pour une clause entière à $n - K$ variables libres, autour de la structure stationnaire préférée C^* à un taux $2(n - K)\gamma_{\min}^{-N}$ (Théorème 7). Sous des conditions explicites d'identifiabilité (dépendance et déséquilibre arbitraires des features, Théorème 10), cette concentration porte sur la véritable conjonction génératrice C_{true} et non plus seulement sur une structure définie

implicitement par P , et reste valide sous un bruit de labels arbitraire de probabilité $\eta < \mu/(S + a)$ (Théorème 12). Ces résultats sont chacun validés empiriquement par simulation directe de la dynamique (Figures 2 et 3) et, pour l'identification, par comparaison directe à PCL sur son propre protocole (Section 6.1).

Ce qui ne l'est pas. Le Théorème 13 montre que chaque round de boosting, pris isolément, est couvert exactement par les résultats ci-dessus (avec P remplacée par la distribution effective Q_m) : l'écart restant n'est donc pas que « la théorie ne dit rien sur le système entraîné », mais que la *composition* entre rounds – convergence du vote pondéré final $\sum_m \alpha_m h_m$ vers un classifieur global – n'est pas analysée. Les résultats sur MNIST à M élevé (8000, 16000) reposent sur un seul run chacun, sans écart-type ; les comparaisons à la TM ne sont pas systématiquement à budget de calcul égal ; PCL n'est pas inclus comme baseline complète en dehors d'Iris et de XOR ; l'ablation de la Section 6.2 isole l'effet des conditions et du boosting sur XOR, mais une étude systématique de $S, a, N, K, M, total$ pris séparément n'a pas été menée à ce stade.

Conclusion. En découplant entièrement la mise à jour de chaque automate de la sortie de la clause et du vote de l'ensemble, la règle à quatre cas admet une analyse de convergence exacte, sous une loi $P(X, Y)$ arbitraire, que ni les machines de Tsetlin ni PCL ne permettent sous cette généralité. Intégrée dans un ensemble conditionné et boosté simple, elle atteint $100\% \pm 0\%$ sur XOR bruité et des performances compétitives sur Iris, Digits et MNIST, tout en laissant ouverte l'analyse de convergence de l'ensemble complet.