

Une règle locale à quatre cas pour les machines de Tsetlin

Analyse de convergence exacte et classifieur conditionné/boosté

Anaïs Hidouche

Réunion d'avancement

Plan

- 1 Analyse théorique
- 2 Classifieur complet
- 3 Résultats empiriques


La règle à quatre cas

$(X_t, Y_t)_{t \geq 1} \stackrel{\text{iid}}{\sim} P$, $P(X, Y)$ arbitraire.

x_i	y	Action sur v_i	Action sur $\bar{v}_i$
0	0	vers Inc (proba S)	vers Exc (proba S)
0	1	vers Exc (proba a)	–
1	0	vers Exc (proba S)	vers Inc (proba S)
1	1	–	vers Exc (proba a)

- $y = 0$: on cherche un littéral *violé* par l'exemple négatif (S).
- $y = 1$: on exclut les littéraux *incompatibles* avec l'exemple positif (a).
- Ne dépend que de (x_i, y) – pas de $C(x)$, pas du vote global.

La chaîne d'un automate



- Chaîne de naissance–mort **homogène** : à chaque état intérieur, p^+ pousse vers Include, p^- pousse vers Exclude ($p^+, p^- > 0$).
- Automate v (littéral x_i) : $p^+ = S P(0,0)$, $p^- = S P(1,0) + a P(0,1)$, $\rho = p^+/p^-$.
- Automate $\bar{v}$ (littéral $\neg x_i$), **même chaîne**, paramètres symétriques : $\bar{p}^+ = S P(1,0)$, $\bar{p}^- = S P(0,0) + a P(1,1)$, $\bar{\rho} = \bar{p}^+/\bar{p}^-$.

Théorème 1 – Loi stationnaire exacte

Théorème 1

Soit $p^+, p^- > 0$ et $\rho = p^+/p^-$. La chaîne (v_t) est irréductible et apériodique sur $\{1, \dots, 2N\}$, donc converge en loi vers l'unique loi stationnaire

$$\pi(k) = \frac{(1-\rho)\rho^{k-1}}{1-\rho^{2N}} \quad (\rho \neq 1), \quad \pi(\text{Inc}) = \frac{\rho^N}{1+\rho^N}.$$

Preuve.

- ❶ **Irréductible** : transitions intérieures $p^+, p^- > 0$ dans les deux sens $\Rightarrow$ tout état atteint tout autre.
- ❷ **Apériodique** : l'état 1 a une auto-boucle ($P(1,1) = 1 - p^+ > 0$) $\Rightarrow$ période 1, donc toute la chaîne (irréductible) est apériodique.
- ❸ **Bilan détaillé** : $\pi(k)p^+ = \pi(k+1)p^- \Rightarrow \pi(k+1)/\pi(k) = \rho$ constant, donc $\pi(k) = \pi(1)\rho^{k-1}$; normalisation $\sum_k \pi(k) = 1$ (série géométrique) donne $\pi(1) = (1-\rho)/(1-\rho^{2N})$, d'où $\pi(k)$; puis $\pi(\text{Inc}) = \sum_{k=N+1}^{2N} \pi(k) = \rho^N/(1+\rho^N)$. ■

Convergence en loi, pas stabilisation p.s. (sauf cas absorbant : $p^+ = 0$ ou $p^- = 0$). Si $\rho > 1$: $1 - \pi(\text{Inc}) \leq \rho^{-N}$.

Lemme de non-contradiction

Définitions (dérives des automates v et $\bar{v}$) :

$$\Delta := p^+ - p^- = S P(0,0) - S P(1,0) - a P(0,1), \quad \bar{\Delta} := \bar{p}^+ - \bar{p}^- = S P(1,0) - S P(0,0) - a P(1,1).$$

$\Delta > 0$ signifie « v est stationnairement poussé vers Include » (et symétriquement pour $\bar{\Delta}, \bar{v}$).

Lemme

Pour toute loi $P(X, Y)$: $\Delta + \bar{\Delta} = -a P(Y=1) \leq 0$. $\Rightarrow$ jamais $\Delta > 0$ et $\bar{\Delta} > 0$ simultanément : la règle ne peut pas favoriser stationnairement l'inclusion des deux littéraux opposés (x_i et $\neg x_i$) en même temps.

Preuve. La somme élimine les termes en S : $\Delta + \bar{\Delta} = -a[P(0,1) + P(1,1)] = -a P(Y=1) \leq 0$, avec égalité ssi $P(Y=1) = 0$. ■

Corollaire : $\Delta > 0 \Rightarrow \bar{\Delta} = -a P(Y=1) - \Delta < 0$ strictement.

Théorème des 3 régimes de sélection

Sens des 3 régimes ($\gamma = \max(\rho, 1/\rho) > 1$, $\bar{\gamma}$ idem pour $\bar{v}$) :

- $\Delta > 0$ (donc $\bar{\Delta} < 0$, Lemme précédent) : à terme $v \rightarrow \text{Inc}$, $\bar{v} \rightarrow \text{Exc}$.
- $\bar{\Delta} > 0$ (donc $\Delta < 0$) : à terme $\bar{v} \rightarrow \text{Inc}$, $v \rightarrow \text{Exc}$.
- $\Delta < 0$ et $\bar{\Delta} < 0$: à terme $v, \bar{v} \rightarrow \text{Exc}$ (littéral neutre).

Théorème

Exactement un des trois régimes a lieu :

$$\Delta > 0 : \lim_N \limsup_t \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc})) = 0 \quad \bar{\Delta} > 0 : \lim_N \limsup_t \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Inc})) = 0$$

$$\Delta < 0 \text{ et } \bar{\Delta} < 0 : \lim_N \limsup_t \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Exc})) = 0$$

Preuve.

- 1 Chaque automate *séparément* (Théorème 1) : $\limsup_t \mathbb{P}(v_t \neq \text{bon côté}) \leq \gamma^{-N}$ et $\limsup_t \mathbb{P}(\bar{v}_t \neq \text{bon côté}) \leq \bar{\gamma}^{-N}$.
- 2 En sommant :

$$\limsup_t \mathbb{P}((v_t, \bar{v}_t) \neq \text{bon régime}) \leq \gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow{N \rightarrow \infty} 0. \quad \blacksquare$$

Théorème – Concentration structurelle multi-features

Sens : le Théorème des 3 régimes portait sur *une* paire $(v, \bar{v})$. Ici on étend à toute une clause : n features, K fixées par une condition, $d = n - K$ libres $\Rightarrow 2d$ automates à surveiller *en même temps*.

Théorème

$$\limsup_{t \rightarrow \infty} \mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \frac{1}{1 + \gamma_j^N} \leq 2(n - K) \gamma_{\min}^{-N}.$$

Preuve, en 3 points.

- 1 Soit A_j : « l'automate j est du mauvais côté ». Si tous les A_j sont faux, alors $C_t = C^*$; par contraposée, $\{C_t \neq C^*\} \subseteq A_1 \cup \dots \cup A_{2d}$.
- 2 $\mathbb{P}(C_t \neq C^*) \leq \sum_j \mathbb{P}(A_j)$, et chaque $\mathbb{P}(A_j) = 1/(1 + \gamma_j^N)$ exactement (Théorème 1).
- 3 On majore chaque terme par le **maillon faible** $\gamma_{\min} = \min_j \gamma_j$ (l'automate le plus lent) : la somme des $2d$ termes donne $2(n - K) \gamma_{\min}^{-N}$. ■

Identification sous dépendance arbitraire

Ce qu'on essaie de démontrer : le Théorème des 3 régimes dit vers quelle structure C^* la règle converge, mais pas si C^* correspond à la *vraie* cible. Ici, on le montre – sous des conditions vérifiables, même si les features sont corrélées et déséquilibrées.

Cadre : $C_{\text{true}}(x) = \bigwedge_{J_+} x_j \wedge \bigwedge_{J_-} (1-x_j)$ (la vraie conjonction), $Y = C_{\text{true}}(X)$, loi jointe **quelconque** (corrélée, déséquilibrée). Pour chaque variable j :


$$A_j = P(X_j=0, Y=0), \quad B_j = P(X_j=1, Y=0), \quad C_j = P(X_j=0, Y=1), \quad D_j = P(X_j=1, Y=1).$$

Théorème 9

Si $A_j > B_j$ pour $j \in J_+$ (resp. $B_j > A_j$ pour J_- , encadrement pour les non pertinents), alors $C^* = C_{\text{true}}$.

Preuve (idée). Pour $j \in J_+$: $Y=1 \Rightarrow X_j=1$, donc $C_j = 0$ et Δ_j se réduit à $S(A_j - B_j)$, positif ssi $A_j > B_j$. Le Lemme de non-contradiction donne alors $\bar{\Delta}_j < 0$ *automatiquement* – pas besoin de le vérifier séparément.

Architecture du classifieur complet



- Chaque clause n'est active que si x satisfait son filtre (condition aléatoire) – sinon elle s'abstient.
- Chaque clause active vote « oui »/« non », pondéré par sa fiabilité α_m .
- On additionne tous les votes actifs ; le signe du total donne la prédiction.

Algorithme (une classe, one-vs-rest)

```
w_i <- 1/|train|
pour m = 1 a M :
  tirer F_m (K features), z_m (config binaire)
  geler les automates de F_m (Exclude, non entraines)
  S_m <- {i : x_i[F_m] = z_m}
  si S_m vide : alpha_m <- 0 ; continuer
  pour t = 1 a total :
    tirer i in S_m selon Q_m (50/50 classe, ~ w_i)
    mettre a jour C_m avec (x_i, 1[y_i=c]) (regle 4 cas)
  si C_m vide : alpha_m <- 0 ; continuer
  err_m <- erreur ponderee de C_m sur S_m (sous D_m)
  alpha_m <- 1/2 ln((1-err_m)/err_m)
  mettre a jour w (exp(+alpha_m)) ; renormaliser
```

Résultats principaux

Dataset	Notre modèle	TM officielle	Meilleure baseline
XOR	100% $\pm$ 0%	97.40% $\pm$ 2.23%	SVM 98.12%
Iris	95.5%	93.50%	RF 95.33%
Digits	97.19%	93.69%	SVM 97.50%
MNIST	95.85% (1 run)	96.62%	SVM 97.71%

- XOR : net, mais budgets non égalisés (clauses différentes).
- MNIST : en dessous de la TM et des baselines classiques – honnête, un seul run à $M=16000$ (limite reconnue).

Balayage S, α – XOR

$S \backslash \alpha$	0,1	0,3	0,35	0,5	0,7	0,9	1,0
0,1	78,1	48,9	48,9	48,9	48,9	48,9	48,9
0,3	86,1	74,2	64,3	48,9	48,9	48,9	48,9
0,5	85,4	91,5	82,7	61,6	48,9	48,9	48,9
0,7	84,1	95,8	89,0	77,0	51,4	48,9	48,9
0,9	81,9	97,5	95,8	80,1	69,4	48,9	48,9
1,0	81,1	98,6	99,1	83,4	75,8	56,5	48,9

$S \backslash \alpha$	0,05	0,1	0,3	0,5	0,7	1,0
0,05	95,5	92,0	89,8	88,0	88,0	88,2
0,1	95,5	95,7	90,7	90,7	89,3	88,0
0,3	95,5	95,5	95,3	90,8	92,0	91,8
0,5	95,5	95,5	95,5	94,8	92,8	92,2
0,7	95,5	95,5	95,5	95,5	95,2	92,8
1,0	95,5	95,5	95,5	95,5	95,5	95,7

Balayage S, α – Digits

$S \backslash \alpha$	0,05	0,1	0,3	0,5	0,7	1,0
0,05	95,6	95,8	96,5	96,4	96,4	97,1
0,1	95,6	95,6	95,8	96,5	96,9	96,5
0,3	95,6	95,6	95,4	96,0	96,0	96,8
0,5	95,6	95,6	95,4	95,6	95,0	96,3
0,7	95,6	95,6	95,4	95,6	95,3	95,0
1,0	95,6	95,6	95,4	95,6	95,6	94,2

$S \backslash \alpha$	0,05	0,1	0,3	0,5	0,7	1,0
0,05	85,9	80,5	58,4	52,7	51,0	39,6
0,1	85,9	85,9	71,5	58,1	51,7	48,8
0,3	85,9	85,9	85,9	77,4	71,7	63,7
0,5	85,9	85,9	85,9	85,9	79,7	74,2
0,7	85,9	85,9	85,9	85,9	85,9	78,8
1,0	85,9	85,9	85,9	85,9	85,9	85,5