

Rapport de session

Extension multi-clause (Option 1) et limites du seuil S^*

Validation empirique sur jeux de données synthétiques et réels

Contents

1	Objectif de la session	2
2	Le routeur	2
3	Résultats validés	2
4	Bugs trouvés et corrigés	3
5	Limites caractérisées (compromis réels, pas des bugs)	4
5.1	Tension S/a : vitesse de convergence vs. robustesse au bruit	4
5.2	Déséquilibre de classe / features quasi-constantes (MNIST)	4
5.3	Le sampling équilibré peut nuire (AND2, Maj3)	4
6	Découverte principale : le seuil S^* ne couvre qu'une variable	5
6.1	Généralisation du seuil à m littéraux	5
7	État actuel — verdict	6
8	Recommandation pour la suite	6

1 Objectif de la session

Étendre la preuve de convergence existante (chaîne de Markov, 1 clause, cas IDENTITY/NOT, `convergence_sans_bruit.tex`) à un réseau **multi-clause**, selon la piste de partition fixe du domaine : la partition est décidée avant l'apprentissage. L'espoir initial était que chaque clause redevienne un sous-problème déjà couvert par la preuve existante — **mais attention, ça ne réduit pas l'entrée à 1 bit** : une clause garde toutes ses n features actives après masquage, seules les features utilisées par le *routage* sont gelées. Ce qui se réduit, dans le meilleur cas, c'est le nombre de **littérales réellement pertinentes** parmi ces features actives (le reste étant non pertinent, géré par le même mécanisme d'annulation que dans le théorème IDENTITY/NOT). Et ce n'est même pas garanti par construction : la section 6 montre des feuilles qui ont besoin de deux littérales pertinentes — hors du cadre du théorème actuel, qui ne couvre qu'une seule variable.

Fichiers créés pendant la session :

- `tsetlin_engine_multiclause.h` — moteur multi-clause (routeur, masquage, calibration, échantillonnage équilibré) ;
- `validation_multiclause.cpp` — XOR et DNF synthétiques ;
- `validation_multiclause_xor_reel.cpp`, `validation_multiclause_reels.cpp`, `validation_multiclause_mnist.cpp` — vrais jeux de données (`data/`).

Le moteur 1-clause d'origine, `tsetlin_engine_4case.h`, n'a **jamais été modifié**.

2 Le routeur

Arbre de décision (CART simplifié) construit sur un batch (x, y) séparé (phase de découverte), puis **gelé** : pendant l'apprentissage il ne prend que x en entrée. Critère de split : impureté de Gini avec **lookahead à 2 niveaux** (évalue le meilleur split atteignable une fois la feature posée, pas seulement son gain immédiat) — nécessaire pour détecter les interactions de type XOR, où aucune feature seule n'apporte de gain individuel.

K est un budget fixé à l'avance, pas une conséquence découverte automatiquement. Une tentative d'arrêter dynamiquement le découpage dès qu'une feuille est représentable par une seule clause (test à la Find-S) a été **abandonnée** : pour la classe des conjonctions, vérifier qu'une solution exacte existe est aussi difficile que la trouver — ce test résolvait la formule cible en coulisses, et la clause n'avait alors plus qu'à reproduire une réponse déjà connue. C'est une erreur méthodologique réelle, détectée et corrigée en cours de session.

3 Résultats validés

Pour juger si une clause apporte une valeur réelle (et pas seulement le découpage), chaque test compare le réseau complet à un **baseline “routeur seul”** : le vote majoritaire de la feuille, sans aucun apprentissage par clause.

Cible	K	accuracy	baseline (routeur seul)	écart
XOR synthétique	2	100%	50.0%	+ 50.0%
XOR réel (40% bruit train)	2	100%	50.1%	+ 49.9%
DNF synthétique (insuffisant)	2	75.0–82.6%	68.8%	+6.2 à +13.8%
DNF synthétique	4	70.3–79.5%	73.0–75.0%	−4.7 à +4.5%
AND2 réel (insuffisant)	1	25.0%	75.0%	− 50.0%
AND2 réel	2	100%	75.0%	+ 25.0%
Maj3 réel (insuffisant)	2	50.7%	75.5%	− 24.8%
Maj3 réel	5	100%	87.2%	+ 12.8%
MNIST (chiffre 0) ¹	2	93.9%	90.3%	+3.6%
MNIST (chiffre 0), K croissant	4–32	91.6–92.5%	90.3%	+1.3 à +2.2%

XOR est la preuve la plus propre : dans chaque feuille, le vote majoritaire est à $\sim 50\%$ (aucune majorité réelle), c’est la clause qui résout le bit restant. Le routeur décide *où regarder* ; la clause *répond*.

Les lignes “insuffisant” (AND2 $K = 1$, Maj3 $K = 2$, DNF $K = 2$) ne sont pas des échecs séparés : elles partagent toutes la même cause, développée en section 6 — au moins une feuille y apprend encore une conjonction de 2 littéraux ou plus, ce que le seuil S^* ne couvre pas à 40% de bruit.

4 Bugs trouvés et corrigés

1. **Masquage des features de routage.** Une feature utilisée pour atteindre une feuille devient constante dans cette feuille ; le mécanisme d’annulation $+S/ - S$ qui exclut normalement les littérales non pertinentes ne s’applique plus. Sans correction, ces features dérivent vers l’inclusion à tort (cassait XOR). Corrigé en gelant ces automates à l’exclusion.
2. **Feuilles “constante à 0”.** Un automate figé exclu donne par défaut une sortie 1 (clause vide) ; une feuille qui doit toujours répondre 0 ne peut pas être représentée en excluant tout. Corrigé en forçant une littérale cohérente avec le chemin de routage (toujours violée) plutôt que de tout exclure.
3. **Détection de pureté non tolérante au bruit.** Même défaut que Find-S (zéro exception tolérée), mais ici sur un simple comptage de fréquence — donc corrigé sans réintroduire la circularité. Remplacé par un seuil tolérant au bruit (`noiseTol`).
4. **Routeur aveugle aux interactions (XOR réel).** Avec des features parasites, un critère à 1 niveau choisit une colonne de bruit au hasard plutôt que les vraies colonnes pertinentes (gain individuel nul pour XOR). Corrigé par le lookahead à 2 niveaux.

¹Pour MNIST, le rappel sur la classe rare passe de 0% ($K = 2$ sans calibration) à 50.9% ($K = 2$, avec calibration S/a + échantillonnage équilibré) puis redescend à 14.1% quand $K = 32$ (dilution du budget, cf. section 6). La colonne “baseline” pour MNIST est le baseline trivial (toujours prédire la classe majoritaire), pas le vote majoritaire par feuille — non recalculé pour chaque K .

5 Limites caractérisées (compromis réels, pas des bugs)

5.1 Tension S/a : vitesse de convergence vs. robustesse au bruit

Sur une feuille dont la fonction restante est un OU (non représentable par une seule clause), la clause converge vers le **ET le plus restrictif** plutôt que vers le repli optimal (clause vide) — pire que le vote majoritaire. Mesuré directement sur le moteur 1-clause isolé : avec $S \geq a$, convergence vers le pire cas (50% sur une cible OU à 2 variables, contre 75% pour la clause vide) ; avec $a > S$, convergence vers le bon repli — mais cela casse la convergence du cas bien représentable (IDENTITY) à partir de $\sim 30\text{--}40\%$ de bruit.

Correction générale apportée : calibration de (S, a) par feuille (fonction `calibrateParams`), dérivée de la même analyse p^+/p^- que le théorème de convergence IDENTITY (`convergence_sans_br`). On mesure, pour chaque feuille, la feature active la plus déséquilibrée et on calibre le rapport S/a au minimum nécessaire. Une bande de tolérance absorbe le bruit d'échantillonnage normal pour ne pas sur-réagir.

Remarque 5.1. `flip(p)` sature à $p \geq 1$: il faut donc **abaisser** S quand a doit dominer, jamais pousser a au-delà de 1 (sinon le rapport réel retombe à 1:1, sans effet).

5.2 Déséquilibre de classe / features quasi-constantes (MNIST)

Sur MNIST un-contre-tous (90% non-cible / 10% cible), le réseau ne prédit jamais la classe rare (rappel = 0%). Cause : 353 des 784 pixels sont quasi-toujours à 0 (fond d'image, indépendant du chiffre) — même mécanisme que ci-dessus mais dans les données brutes, pas dans le routage.

Correction générale apportée : un échantillonneur équilibré (`BalancedSampler`, présente les exemples positifs/négatifs 50/50 pendant l'apprentissage, lu directement depuis les labels du jeu fourni, sans ratio supposé à l'avance), combiné à la calibration ci-dessus. Résultat : accuracy 90.3% $\rightarrow$ 93.9%, rappel 0% $\rightarrow$ 50.9%, avec les mêmes paramètres de base partout ($S = 1$, $a = 0.3$, jamais réglés à la main par jeu de données).

5.3 Le sampling équilibré peut nuire (AND2, Maj3)

Sur une cible AND2 ($x_1 \wedge x_2$, vraie 25% du temps) avec 40% de bruit sur le label : dans le sous-ensemble étiqueté “oui”, les faux positifs sont **deux fois plus nombreux** que les vrais positifs, simplement parce que les vrais négatifs sont trois fois plus fréquents au départ. Forcer un tirage 50/50 amplifie l'exposition à ce bruit majoritaire au lieu de le diluer. Résultat avec $K = 1$: accuracy 25% (pire que le hasard), clause vide.

C'est l'**inverse exact** du problème précédent : là, équilibrer corrigeait un déséquilibre de *features* ; ici, équilibrer un déséquilibre de *classe* amplifie le bruit sur la classe rare. **Aucun correctif général trouvé cette session n'est gratuit.**

6 Découverte principale : le seuil S^* ne couvre qu'une variable

En cherchant la cause profonde de la section précédente, un test décisif a été mené sur le moteur **1-clause d'origine, intact**, sans aucun ajout de cette session :

Bruit (cible $x_1 \wedge x_2$, 2 littéraux)	exactitude
30%	100%
35%	100%
40%	0% (accuracy 25%, casse net)

Le moteur d'origine lui-même bascule entre 35% et 40% de bruit pour une conjonction de **deux** variables — alors que le théorème de convergence IDENTITY ne couvre que les cibles à **une** variable. AND2 et Maj3 ont justement $\sim 40\%$ de bruit dans leurs fichiers réels : ils tombent exactement dans la zone non couverte par la théorie actuelle.

Confirmation croisée : AND2 avec $K = 2$ (qui découpe sur x_2 , réduisant chaque feuille à une seule variable pertinente) donne 100% — alors que $K = 1$ (qui force la clause à apprendre la conjonction des deux variables directement) donne 25%. Le découpage n'aide pas par hasard : il **réduit le problème au régime que la théorie couvre déjà**.

Remarque 6.1. Ce n'est pas un bug — c'est une lacune non caractérisée de la théorie existante, qui explique d'un coup AND2, Maj3, et participe à la tension S/a de la section précédente.

6.1 Généralisation du seuil à m littéraux

Le théorème de convergence IDENTITY (avec bruit) ne couvre qu'une cible à **une** variable. On généralise ici au cas d'une conjonction de m littéraux positifs $x_1 \wedge \dots \wedge x_m$, avec x_i i.i.d. Bernoulli($c=0.5$) et bruit de label symétrique b (comme dans `sampleLabeledBatch`). On reprend exactement le calcul p^+/p^- du théorème existant, appliqué à l'automate $v[1]$ (par symétrie, identique pour $v[1..m]$).

Pour $x_1 = 0$, la conjonction est toujours fausse, donc $y_{\text{vrai}} = 0$; pour $x_1 = 1$, $y_{\text{vrai}} = 1$ avec probabilité $\pi' = 2^{-(m-1)}$ (les $m - 1$ autres littéraux doivent aussi être à 1). En notant a le paramètre d'exclusion de l'engin (le α du théorème existant) :

$$\begin{aligned} p_{v[1]}^+ &= P(x_1=0, y=0) S = \frac{1}{2}(1-b) S, \\ p_{v[1]}^- &= P(x_1=0, y=1) a + P(x_1=1, y=0) S = \frac{1}{2} b a + \frac{1}{2} \left[(1-\pi')(1-b) + \pi' b \right] S. \end{aligned}$$

La condition $\rho_{v[1]} = p_{v[1]}^+/p_{v[1]}^- > 1$ se simplifie (mêmes étapes que pour le cas $m = 1$) en :

$$S \pi' (1 - 2b) > b a \quad \Longleftrightarrow \quad \boxed{S^*(m, b) = \frac{a b 2^{m-1}}{1 - 2b}}$$

Le seuil critique de bruit $b^*(m)$ — le point où $S^*(m, b^*) = 1$, donc où même $S = 1$ (le maximum) ne suffit plus — vaut :

$$b^*(m) = \frac{1}{2 + a \cdot 2^{m-1}}.$$

Validation empirique (trois points indépendants, $a = 0.3$)

m	b^* prédit	Observé (moteur 1-clause intact)	Source
1 ($a = 1$)	33.3%	33.3%	déjà publié (Test A)
2	38.5%	marche à 35%, casse à 40%	AND2 (cette session)
3	31.25%	marche à 30%, transition à 31%, cassé à 32%	testé pour valider la formule

Pour $m = 3$, la prédiction (31.25%) tombe exactement entre les deux points de test les plus proches (30% encore bon, 32% déjà cassé), avec une transition observée à 31% (33% d’exactitude, ni 100% ni 0%) — la signature attendue d’un seuil franchi de peu. La formule explique aussi pourquoi b^* **décroît** avec m : chaque littéral supplémentaire divise par deux la fréquence du signal positif, donc le bruit a proportionnellement plus de poids face à un signal de plus en plus rare.

Remarque 6.2. Cette formule donne, pour une cible et un niveau de bruit donnés, le K minimal nécessaire **par calcul direct** (réduire chaque feuille jusqu’à ce que son nombre de littéraux pertinents m satisfasse $b < b^*(m)$) — au lieu du balayage empirique fait cette session pour AND2 et Maj3.

Contre-exemple : MNIST ne suit pas ce principe

Sur MNIST, augmenter K ($2 \rightarrow 32$) **dégrade** systématiquement le rappel ($50.9\% \rightarrow 14.1\%$), à l’opposé de AND2/Maj3. Hypothèse retenue mais **non encore vérifiée** : dilution du budget (300 exemples de découverte et 10^5 pas d’apprentissage, répartis sur de plus en plus de feuilles). Le principe “découper jusqu’à une variable par feuille” semble spécifique aux cibles à structure logique propre (peu de littéraux réellement responsables) ; MNIST n’a pas cette structure (motif diffus sur toute l’image).

7 État actuel — verdict

- Le **mécanisme central** (partition figée + convergence par clause) est validé, y compris sur données réelles, avec une méthodologie (baseline routeur seul) qui prouve que les clauses font un travail réel.
- Le **système complet**, avec les correctifs généraux ajoutés (sampling équilibré, calibration S/a), n’est pas universellement robuste : chaque correctif aide certains jeux de données et nuit à d’autres. La calibration S/a par feuille est la seule correction qui, jusqu’ici, n’a cassé aucun cas testé.
- La vraie limite identifiée n’est **pas** dans le code multi-clause, mais dans le seuil S^* du moteur 1-clause d’origine, jamais caractérisé pour des cibles à plusieurs littéraux.

8 Recommandation pour la suite

Prioriser la généralisation théorique du seuil S^* à une conjonction de m littéraux (étendre le théorème de convergence IDENTITY bruité), plutôt que de continuer à

corriger jeu de données par jeu de données. C'est la pièce qui transforme les observations de cette session (AND2, Maj3, tension S/a) en un résultat théorique unique et citable, et qui permettrait de calculer directement, pour une cible donnée, le K minimal nécessaire — au lieu de le découvrir par balayage empirique.

En secondaire : vérifier l'hypothèse de dilution de budget sur MNIST (batch de découverte et budget d'entraînement proportionnels à K).