

Analyse théorique de la règle à 4 cas

Cette section prouve la convergence de la règle locale à 4 cas elle-même et pas le système complet :

Soit $(X_t, Y_t)_{t \geq 1} \stackrel{\text{i.i.d.}}{\sim} P$ de loi jointe $P(X, Y)$ arbitraire. Deux automates à $2N$ états gouvernent le littéral x et sa négation : v et $\bar{v}$, avec $\text{included}(s) = \mathbf{1}[s > N]$.

x	y	Action sur v	Action sur $\bar{v}$
0	0	vers Inc(S)	vers Exc(S)
0	1	vers Exc(a)	–
1	0	vers Exc(S)	vers Inc(S)
1	1	–	vers Exc(a)

avec $S, a \in (0, 1]$. Les probabilités de transition intérieures s'écrivent, pour toute loi P :

$$p^+ = S P(0, 0), \quad p^- = S P(1, 0) + a P(0, 1); \quad (1)$$

$$\bar{p}^+ = S P(1, 0), \quad \bar{p}^- = S P(0, 0) + a P(1, 1). \quad (2)$$

Loi stationnaire exacte

Théorème 1. *Soit $\rho = p^+/p^-$, avec $p^+, p^- > 0$. La chaîne (v_t) est irréductible et apériodique sur $\{1, \dots, 2N\}$, donc $\mathcal{L}(v_t) \xrightarrow[t \rightarrow \infty]{} \pi$ (convergence en loi vers l'unique loi stationnaire, théorème ergodique standard pour les chaînes de Markov finies irréductibles apériodiques), de loi stationnaire*

$$\pi(k) = \frac{(1 - \rho)\rho^{k-1}}{1 - \rho^{2N}} \quad (\rho \neq 1), \quad \pi(k) = \frac{1}{2N} \quad (\rho = 1), \quad \pi(\text{Inc}) = \frac{\rho^N}{1 + \rho^N}.$$

Si $\rho > 1$: $\pi(\text{Inc}) \rightarrow 1$ et $1 - \pi(\text{Inc}) \leq \rho^{-N}$. Si $\rho < 1$: $\pi(\text{Exc}) \rightarrow 1$ symétriquement. De plus $\frac{1}{T} \sum_{t \leq T} \mathbf{1}[v_t > N] \rightarrow \pi(\text{Inc})$ p.s. Attention : ceci est une convergence en loi (stationnaire) et une convergence p.s. de la fréquence temporelle – pas une convergence p.s. de v_t vers un état fixe. Dans le cas ergodique ($p^+, p^- > 0$), l'automate continue de se déplacer indéfiniment ; il n'y a stabilisation permanente que dans le cas absorbant (Corollaire 2).

Proof. Irréductibilité. Chaîne de naissance-mort à transitions intérieures strictement positives.

Noyau explicite. Pour $2 \leq k \leq 2N - 1$: $P(k, k+1) = p^+$, $P(k, k-1) = p^-$, $P(k, k) = 1 - p^+ - p^-$. Aux bornes (troncature) : $P(1, 1) = 1 - p^+$, $P(1, 2) = p^+$, $P(2N, 2N) = 1 - p^-$, $P(2N, 2N-1) = p^-$.

Apériodicité. $P(1, 1) = 1 - p^+ \geq p^- > 0$: l'état 1 a un cycle de longueur 1, donc une période $d(1) = 1$. Par irréductibilité, la période est une propriété de classe : toute la chaîne est apériodique.

Forme géométrique. Bilan détaillé $\pi(k)p^+ = \pi(k+1)p^-$ donne $\pi(k+1)/\pi(k) = \rho$ constant, soit $\pi(k) = \pi(1)\rho^{k-1}$; normalisation $\sum_{k=1}^{2N} \pi(k) = 1 = \pi(1) \sum_{k=0}^{2N-1} \rho^k$ donne $\pi(1) = (1 - \rho)/(1 - \rho^{2N})$ (série géométrique finie), d'où les formules annoncées. $\pi(\text{Inc}) = \sum_{k=N+1}^{2N} \pi(k) = \pi(1)\rho^N \sum_{k=0}^{N-1} \rho^k = \pi(1)\rho^N(1 - \rho)/(1 - \rho) = \rho^N(1 - \rho)/(1 - \rho^{2N}) = \rho^N/(1 + \rho^N)$. La convergence p.s. de la moyenne temporelle est le théorème ergodique standard. $\square$

Corollaire 2 (Cas absorbant). *Si $p^- = 0, p^+ > 0$: absorption p.s. en $2N$ en temps fini, $\mathbb{E}[T_{2N}] = (2N - s_0)/p^+$; première entrée dans Inc (franchissement de N), généralement plus rapide, $\mathbb{E}[T_{\text{Inc}}] = (N + 1 - s_0)_+/p^+$. Si $p^+ = 0, p^- > 0$: symétrique en $1/\text{Exc}$. Si $p^+ = p^- = 0$: aucune transition ne se produit jamais (chaque état trivialement absorbant), l'automate reste figé à s_0 .*

Exclusion des dérives contradictoires

Lemme 3. *Soit $\Delta = p^+ - p^-$, $\bar{\Delta} = \bar{p}^+ - \bar{p}^-$. Pour toute loi $P(X, Y)$:*

$$\Delta + \bar{\Delta} = -a P(Y=1) \leq 0.$$

Si $P(Y=1) > 0$, l'inégalité est stricte : $\Delta + \bar{\Delta} < 0$, donc $\Delta = \bar{\Delta} = 0$ simultanément est impossible. Si $P(Y=1) = 0$ (cas dégénéré), $\Delta + \bar{\Delta} = 0$ exactement.

Proof. De (1)–(2) : $\Delta = S P(0, 0) - S P(1, 0) - a P(0, 1)$, $\bar{\Delta} = S P(1, 0) - S P(0, 0) - a P(1, 1)$. La somme élimine les termes en S : $\Delta + \bar{\Delta} = -a[P(0, 1) + P(1, 1)] = -a P(Y=1) \leq 0$, avec égalité ssi $P(Y=1) = 0$ (puisque $a > 0$). $\square$

Corollaire 4. *Si $\Delta > 0$ alors $\bar{\Delta} = -a P(Y=1) - \Delta < 0$ strictement.*

Remarque 5. *Le lemme exclut $\Delta > 0$ et $\bar{\Delta} > 0$ simultanément ; il n'exclut pas $\Delta < 0$ et $\bar{\Delta} < 0$ simultanément (double exclusion, régime neutre). Pour N fini et $\rho \neq 1$, l'état instantané peut néanmoins se trouver du mauvais côté avec probabilité $\leq \rho^{-N} \rightarrow 0$.*

Sélection sous loi arbitraire

Théorème 6. *Supposons $\Delta \neq 0$ et $\bar{\Delta} \neq 0$. Notons $\gamma = \max(\rho, 1/\rho) > 1$, $\bar{\gamma} = \max(\bar{\rho}, 1/\bar{\rho}) > 1$ (probabilité du mauvais côté toujours $\leq \gamma^{-N}$, resp. $\bar{\gamma}^{-N}$, quel que soit le signe de $\Delta, \bar{\Delta}$). Alors exactement un des trois régimes suivants a lieu :*

- $\Delta > 0$ (donc $\bar{\Delta} < 0$) $\iff S P(0, 0) > S P(1, 0) + a P(0, 1)$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}\left((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc})\right) = 0.$$

- $\bar{\Delta} > 0$ (donc $\Delta < 0$) $\iff S P(1, 0) > S P(0, 0) + a P(1, 1)$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}\left((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Inc})\right) = 0.$$

- $\Delta < 0$ et $\bar{\Delta} < 0$:

$$\lim_{N \rightarrow \infty} \limsup_{t \rightarrow \infty} \mathbb{P}\left((v_t, \bar{v}_t) \neq (\text{Exc}, \text{Exc})\right) = 0.$$

Proof. Les équivalences découlent de (1)–(2). L'exclusion mutuelle des trois régimes découle du Corollaire 4. Passage du marginal au joint (cas $\Delta > 0$: $\rho > 1$ donc $\gamma = \rho$, $\bar{\rho} < 1$ donc $\bar{\gamma} = 1/\bar{\rho}$; similaire ailleurs), *sans* invoquer de loi stationnaire jointe (la chaîne $(v_t, \bar{v}_t)$ n'est pas nécessairement irréductible – ex. $S=1$, $P(Y=1)=0$ conserve $v_t + \bar{v}_t$). En prenant d'abord $\limsup_{t \rightarrow \infty}$ (la borne du Théorème 1 porte sur la loi *stationnaire*, atteinte seulement asymptotiquement en t – fausse pour un t petit et une initialisation arbitraire), puis par union bound,

$$\limsup_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Inc}, \text{Exc})) \leq \limsup_{t \rightarrow \infty} \mathbb{P}(v_t \neq \text{Inc}) + \limsup_{t \rightarrow \infty} \mathbb{P}(\bar{v}_t \neq \text{Exc}) \leq \gamma^{-N} + \bar{\gamma}^{-N},$$

sans hypothèse d'indépendance entre v_t et $\bar{v}_t$. Puis $\gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow{N \rightarrow \infty} 0$ donne la double limite annoncée. Noter $\bar{\gamma}^{-N} = \bar{\rho}^N$ ici (pas $\bar{\rho}^{-N}$, puisque $\bar{\rho} < 1$) : c'est pour éviter cette confusion de signe que $\gamma = \max(\rho, 1/\rho)$ est défini une fois pour toutes. $\square$

Concentration multi-bit

Théorème 7. *Clause à n features, K fixées par la condition, $d = n - K$ libres gouvernées par $2d$ automates. Pour chaque automate j (préférence stationnaire non dégénérée), $r_j = p_j^+ / p_j^-$, $\gamma_j = \max(r_j, 1/r_j) > 1$, $\gamma_{\min} = \min_j \gamma_j$. Alors, sans hypothèse d'indépendance, l'erreur de récupération structurelle vérifie :*

$$\limsup_{t \rightarrow \infty} \mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \frac{1}{1 + \gamma_j^N} \leq 2(n - K) \gamma_{\min}^{-N} \xrightarrow{N \rightarrow \infty} 0.$$

Proof. Soit A_j l'évènement « l'automate j est du mauvais côté ». Si tous les A_j sont faux, chaque automate est dans son état préféré, donc $C_t = C^*$; par contraposée, $\{C_t \neq C^*\} \subseteq A_1 \cup \dots \cup A_{2d}$, d'où par l'union bound (Boole) :

$$\mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \mathbb{P}(A_j).$$

Par le Théorème 1, $\mathbb{P}(A_j) = \pi(\text{Exc}) = 1/(1 + r_j^N)$ si $r_j > 1$, ou $\pi(\text{Inc}) = r_j^N/(1 + r_j^N)$ si $r_j < 1$ – dans les deux cas exactement $1/(1 + \gamma_j^N)$, d'où la première inégalité. Ensuite, $1/(1 + \gamma_j^N) < \gamma_j^{-N}$ (dénominateur plus grand), et $\gamma_j \geq \gamma_{\min}$ donne $\gamma_j^{-N} \leq \gamma_{\min}^{-N}$; en remplaçant chacun des $2d$ termes par cette même borne on obtient $2(n - K) \gamma_{\min}^{-N}$. $\square$

Application : ensemble conditionné et boosté

On intègre la règle à 4 cas dans un ensemble conditionné (gates aléatoires) et boosté (AdaBoost) pour illustrer son utilité pratique en classification. **L'analyse de convergence complète de cet ensemble – couverture des conditions sous la distribution adaptative Q_m , et convergence du vote pondéré final – n'est pas prouvée ici et reste un travail futur.** Les résultats ci-dessous (couverture, boosting) caractérisent des propriétés partielles utiles mais ne ferment pas cette boucle.

Algorithme

Classifieur multiclasse one-vs-rest : une classe c est traitée par l'algorithme ci-dessous, indépendamment des autres.

Entrée : dataset $\{(x_i, y_i)\}$, n features, N états, M clauses, K features gelées/clause, *total* tirages/clause, S, a .

$w_i \leftarrow 1/|\text{train}|$ pour tout i

pour $m = 1$ à M :

tirer $F \subseteq \{1, \dots, n\}$, $|F| = K$, uniformément (shuffle)

tirer $v \in \{0, 1\}^K$ uniformément (pile-ou-face indépendant/feature)

créer une clause C_m conditionnée sur (F, v) ; geler ces K littéraux

$S_m \leftarrow \{i : (x_i)_F = v\}$

si $S_m = \emptyset$: $\alpha_m \leftarrow 0$; **continuer**

pour $t = 1$ à *total* :

tirer $i \in S_m$ selon Q_m (50/50 classe, puis $\propto w_i$ dans la classe)

mettre à jour C_m avec $(x_i, \mathbf{1}[y_i=c])$ (règle à 4 cas)

si C_m vide (aucun littéral inclus) : $\alpha_m \leftarrow 0$; **continuer** (pas

de mise à jour des poids)

$\text{err}_m \leftarrow \sum_{i \in S_m} w_i \mathbf{1}[C_m(x_i) \neq \mathbf{1}[y_i=c]] / \sum_{i \in S_m} w_i$ (sous D_m)

$\text{err}_m \leftarrow \text{clip}(\text{err}_m, \epsilon, 1 - \epsilon)$

$\alpha_m \leftarrow \frac{1}{2} \ln((1 - \text{err}_m)/\text{err}_m)$

pour $i \in S_m$: $w_i \leftarrow w_i \cdot \exp(\pm \alpha_m)$ (signe + si erreur, - sinon)

renormaliser w sur tout le dataset

retourner $(C_1, \dots, C_M), (\alpha_1, \dots, \alpha_M)$

Prédiction. Pour x et chaque classe c :

$$\text{score}_c(x) = \sum_{m=1}^M \alpha_{c,m} \cdot (2 C_{c,m}(x) - 1) \cdot \mathbf{1}[(x)_{F_{c,m}} = v_{c,m}] \cdot \mathbf{1}[C_{c,m} \text{ non vide}],$$

puis $\hat{y} = \arg \max_c \text{score}_c(x)$ (clause ignorée si son gate n'est pas satisfait par x ou si elle est vide).

Validation empirique

Comparaison de notre modèle à la Tsetlin Machine officielle (`pyTsetlinMachine`, configurations publiées) et à cinq baselines classiques (`scikit-learn`, hyperparamètres par défaut). Tous les modèles sont évalués sur les mêmes fichiers de données et, quand un remélange est nécessaire, la même seed par run (20000 + run). Écart-type rapporté : $\sqrt{\frac{1}{R} \sum_r (\text{acc}_r - \text{acc})^2}$ (écart-type empirique de population, $1/R$, pas l'estimateur non biaisé $1/(R-1)$). **Budgets non égalisés** entre notre modèle et la TM (nombre de clauses différent par dataset, cf. ci-dessous) : ces comparaisons ne sont donc pas encore à budget de calcul égal. PCL (AAAI-25, related work le plus proche) n'est pas inclus systématiquement : dans nos tests, PCL s'effondre sur XOR bruité avec ses hyperparamètres publiés (toutes les clauses restent vides) ; il reste pertinent là où il fonctionne (Iris, $\approx 82\%$ observé séparément).

XOR

Fichiers fixes (`NoisyXORTrainingData.txt/TestData.txt`, 5000/5000), aucun remélange. Notre modèle : $M=200$, $K=1$, $S=1.0$, $a=0.35$, $N=50$, *total*=5000. TM : 20 clauses, $T=15$, $s=3.9$, 200 epochs. 20 runs partout.

Modèle	Précision
Notre modèle	100% $\pm$ 0%
Tsetlin Machine (officielle)	97.40% $\pm$ 2.23%
SVM	98.12% $\pm$ 0%
MLP	76.72% $\pm$ 1.97%
Random Forest	66.52% $\pm$ 0.30%
Régression logistique	48.94% $\pm$ 0%
Naive Bayes	49.12% $\pm$ 0%

Iris

Fichier unique (`BinaryIrisData.txt`, 149 exemples), remélangé 80/20 à chaque run. Notre modèle : $M=1500$, $K=2$, $S=1.0$, $a=0.3$, $N=100$, $total=20000$. TM : 300 clauses, $T=10$, $s=3.0$, 500 epochs. 20 runs partout.

Modèle	Précision
Notre modèle	95.5% $\pm$ 4.25%
Random Forest	95.33% $\pm$ 3.86%
MLP	94.50% $\pm$ 3.38%
Tsetlin Machine (officielle)	93.50% $\pm$ 4.28%
SVM	92.67% $\pm$ 4.03%
Régression logistique	92.50% $\pm$ 4.70%
Naive Bayes	90.67% $\pm$ 4.29%

Notre modèle et Random Forest sont dans la marge de bruit l'un de l'autre.

Digits

Fichiers fixes (`BinaryDigitsTrainingData192.txt/TestData192.txt`, 1437/360), aucun remélange. Notre modèle : $M=2000$, $K=2$, $S=0.05$, $a=1.0$, $N=100$, $total=20000$. TM : 1000 clauses, $T=10$, $s=3.0$, 300 epochs. 10 runs partout.

Modèle	Précision
Notre modèle	97.19% $\pm$ 0.40%
SVM	97.50% $\pm$ 0%
Random Forest	97.31% $\pm$ 0.31%
MLP	97.17% $\pm$ 0.41%
Régression logistique	96.11% $\pm$ 0%
Tsetlin Machine (officielle)	93.69% $\pm$ 0.76%
Naive Bayes	91.39% $\pm$ 0%

MNIST

Fichiers fixes (`MNISTTraining.txt/Test.txt`, 60000/10000), aucun remélange. Notre modèle : $M=16000$, $K=2$, $S=1.0$, $a=0.3$, $N=100$, $total=20000$. TM : 4000 clauses/classe, $T=50$, $s=10.0$, 20 epochs.

Modèle	Précision
SVM	97.71% $\pm$ 0%
Random Forest	97.07% $\pm$ 0.06%
MLP	96.90% $\pm$ 1.03%
Tsetlin Machine (officielle, 4000 clauses/classe)	96.62% $\pm$ 0.07% (3 runs)
Notre modèle ($M=16000$ /classe)	95.85% (1 run)
Régression logistique	91.89% $\pm$ 0%
Notre modèle ($M=4000$ /classe, budget égal TM)	93.56% (1 run)
Naive Bayes	84.23% $\pm$ 0%