

Théorie consolidée de la règle à 4 cas

Automate isolé, sélection de littéral, extension multi-bit — base pour
la Section 4 (AAAI)

Contents

1	Cadre général	2
2	Théorème 1 — loi stationnaire exacte (cas général)	2
3	Lemme de non-contradiction	4
4	Critère de sélection sous distribution arbitraire	4
5	Extension multi-bit : borne de concentration pour une clause	6
6	Couverture des conditions aléatoires : garantie d'ensemble	7
7	Analyse par round sous les distributions induites par le boosting	8
8	Validation empirique — déjà réalisée	10

1 Cadre général

Soit $(X, Y) \in \{0, 1\}^2$ un couple aléatoire de loi jointe $P(X, Y)$ arbitraire (pas nécessairement IDENTITY/NOT), et $(X_t, Y_t)_{t \geq 1} \stackrel{\text{i.i.d.}}{\sim} P$ la suite des observations présentées à la règle – hypothèse maintenue dans toute la suite du document, nécessaire pour que chaque automate soit une chaîne de Markov homogène à probabilités de transition constantes p^+, p^- (sans elle, si les observations sont corrélées dans le temps ou si P dérive, l'automate seul n'est pas garanti être une chaîne de Markov homogène). Deux automates gouvernent le littéral x et sa négation : v (état $s_1 \in \{1, \dots, 2N\}$) et $\bar{v}$ (état s_2), avec $\text{included}(s) = \mathbf{1}[s > N]$. La règle à 4 cas, appliquée à chaque observation (x, y) :

x	y	Action sur v	Action sur $\bar{v}$
0	0	versInclude (S)	versExclude (S)
0	1	versExclude (a)	rien
1	0	versExclude (S)	versInclude (S)
1	1	rien	versExclude (a)

avec $S, a \in (0, 1]$. En agrégeant sur (X, Y) , les probabilités de transition intérieures de v et $\bar{v}$ s'écrivent, pour *toute* loi jointe P :

$$p^+ = S \cdot P(X=0, Y=0), \quad p^- = S \cdot P(X=1, Y=0) + a \cdot P(X=0, Y=1); \quad (1)$$

$$\bar{p}^+ = S \cdot P(X=1, Y=0), \quad \bar{p}^- = S \cdot P(X=0, Y=0) + a \cdot P(X=1, Y=1). \quad (2)$$

Note 1.1 (Lien avec la paramétrisation (c, p_1, p_0)). Le cadre IDENTITY/NOT déjà utilisé dans *Démonstration de convergence* ($c=P(X=1)$, cette référence notant $a=P(Y=1 \mid X=1)$ et $b=P(Y=1 \mid X=0)$ – renommés ici p_1, p_0 pour éviter toute collision avec le paramètre de règle a introduit ci-dessous, sans lien avec ces probabilités de bruit) est le cas particulier $P(0, 0)=(1-c)(1-p_0)$, $P(1, 0)=c(1-p_1)$, $P(0, 1)=(1-c)p_0$, $P(1, 1)=cp_1$. Toutes les formules ci-dessous se réduisent aux formules déjà publiées dans *Démonstration de convergence* en substituant ces expressions — vérifié terme à terme, aucune contradiction.

2 Théorème 1 — loi stationnaire exacte (cas général)

Théorème 2.1 (Loi stationnaire, automate isolé). *Soit $\rho = p^+/p^-$ (resp. $\bar{\rho} = \bar{p}^+/\bar{p}^-$), avec $p^+, p^- > 0$ (cas ergodique, aucune des deux directions n'est bloquée). La chaîne $(v(t))_t$ est irréductible et apériodique sur $\{1, \dots, 2N\}$, et sa loi stationnaire est géométrique, de normalisation exacte :*

$$\pi(k) = \frac{(1-\rho)\rho^{k-1}}{1-\rho^{2N}} \quad (\rho \neq 1), \quad \pi(k) = \frac{1}{2N} \quad (\rho = 1), \quad \boxed{\pi(\text{Include}) = \sum_{k>N} \pi(k) = \frac{\rho^N}{1+\rho^N}.$$

Si $\rho > 1$, $\pi(\text{Include}) > \frac{1}{2}$ et $\pi(\text{Include}) \xrightarrow[N \rightarrow \infty]{} 1$, avec $1 - \pi(\text{Include}) \leq \rho^{-N}$; si $\rho < 1$, $\pi(\text{Exclude}) \rightarrow 1$ symétriquement. De plus, par le théorème ergodique pour les chaînes de Markov irréductibles apériodiques à espace d'états fini,

$$\frac{1}{T} \sum_{t=1}^T \mathbf{1}[v_t > N] \xrightarrow[T \rightarrow \infty]{p.s.} \pi(\text{Include}),$$

ce qui relie directement la loi stationnaire à la métrique expérimentale « fraction du temps passé dans la bonne action ». Idem pour $\bar{v}$ avec $\bar{\rho}$.

Proof. Irréductibilité : chaîne de naissance-mort à transitions intérieures strictement positives ($p^+, p^- > 0$). Apériodicité : ne dépend pas de $1 - p^+ - p^- > 0$ (cette quantité n'est pas nécessairement strictement positive) ; elle découle des boucles réflexives aux deux bornes de l'espace d'états – en $k = 1$, une poussée supplémentaire vers Exclude laisse l'état inchangé ($\max(1, k - 1) = 1$), et en $k = 2N$, une poussée supplémentaire vers Include laisse l'état inchangé – ce qui donne un état apériodique, et donc, par irréductibilité, une chaîne entièrement apériodique. Unicité de π par le théorème ergodique ; forme géométrique par bilan détaillé ($\pi(k)p^+ = \pi(k+1)p^- \Rightarrow \pi(k+1)/\pi(k) = \rho$ constant) ; somme géométrique pour $\pi(\text{Include}) = \sum_{k>N} \pi(k)$. La convergence p.s. de la moyenne temporelle est le théorème ergodique standard appliqué à l'indicatrice $\mathbf{1}[\cdot > N]$. Aucune hypothèse sur la forme de $P(X, Y)$ n'est utilisée dans cette preuve : elle ne dépend que du rapport $\rho = p^+/p^-$, quelle que soit la loi jointe sous-jacente. $\square$

Note 2.1 (Terminologie : convergence en distribution, pas absorption). Le terme *absorption* est réservé au cas unidirectionnel (Corollaire 2.2, $p^- = 0$ ou $p^+ = 0$). Dans le cas ergodique ($p^+, p^- > 0$), l'automate ne se fixe *jamais* définitivement : il continue de se déplacer indéfiniment et converge seulement *en distribution* vers π . « Sans bruit » n'implique donc pas absorption : pour une conjonction comme $Y = X_1 \wedge X_2$, un automate peut recevoir des poussées dans les deux sens même en l'absence de bruit sur Y , car les autres combinaisons de (X_1, X_2) jouent un rôle symétrique à celui du bruit.

Corollaire 2.2 (Cas unidirectionnel absorbant). *Trois cas distincts, à distinguer explicitement :*

- $p^- = 0, p^+ > 0$: chaîne de naissance pure (aucune poussée vers Exclude), absorbée p.s. en $2N$ en temps fini, $\rho \rightarrow \infty$. Deux temps d'arrêt distincts sont pertinents et ne doivent pas être confondus : le temps d'absorption complète en $2N$, $\mathbb{E}[T_{2N}] = (2N - s_0)/p^+$ (loi négative binomiale, cf. Lemme 3.1 de *Démonstration de convergence*), et le temps, généralement plus court, de première entrée dans la région Include (franchissement de N), pertinent pour le comportement du classifieur : $\mathbb{E}[T_{\text{Include}}] = (N + 1 - s_0)_+/p^+$ (où $(\cdot)_+ = \max(\cdot, 0)$, nul si $s_0 > N$, l'automate étant déjà inclus) ;
- $p^+ = 0, p^- > 0$: symétrique, absorption p.s. en 1, $\mathbb{E}[T_1] = (s_0 - 1)/p^-$, première entrée dans Exclude (franchissement de $N+1$) en $\mathbb{E}[T_{\text{Exclude}}] = (s_0 - N)_+/p^-$;
- $p^+ = p^- = 0$: l'automate ne reçoit aucun signal ; chaque état est trivialement absorbant au sens où aucune transition ne se produit jamais (et non « non absorbant » – il n'y a simplement pas de dynamique du tout). L'automate reste figé à son état initial s_0 , cas exclu du Théorème 5.1.

Les deux premiers cas sont les cas particuliers $\rho = \infty$ et $\rho = 0$ du Théorème 2.1.

3 Lemme de non-contradiction

Lemme 3.1 (Exclusion des dérives simultanément positives). *Notons $\Delta = p^+ - p^-$ et $\bar{\Delta} = \bar{p}^+ - \bar{p}^-$ (les drifts nets de v et $\bar{v}$). Alors, pour toute loi $P(X, Y)$:*

$$\Delta + \bar{\Delta} = -a \cdot P(Y=1) \leq 0.$$

Proof. D'après (1)–(2) :

$$\begin{aligned}\Delta &= S P(0, 0) - S P(1, 0) - a P(0, 1), \\ \bar{\Delta} &= S P(1, 0) - S P(0, 0) - a P(1, 1).\end{aligned}$$

En sommant, les termes en $S P(0, 0)$ et $S P(1, 0)$ s'annulent deux à deux :

$$\Delta + \bar{\Delta} = -a [P(0, 1) + P(1, 1)] = -a P(Y=1) \leq 0$$

puisque $a > 0$ et $P(Y=1) \geq 0$. □

Note 3.1 (Interprétation : exclusion asymptotique, pas instantanée). v et $\bar{v}$ ne peuvent donc jamais avoir *simultanément* un drift net strictement positif ($\Delta > 0$ et $\bar{\Delta} > 0$) : la règle empêche la configuration « contradiction » ($x \wedge \neg x$, ligne 1 du tableau sémantique) d'être la configuration *asymptotiquement favorisée*. Elle n'empêche en revanche pas les deux drifts d'être simultanément *négatifs* ($\Delta < 0$ et $\bar{\Delta} < 0$, régime neutre du Théorème 4.1) : le lemme exclut seulement la double inclusion, pas la double exclusion. Il ne dit rien non plus sur l'état à un instant t fini : par le Théorème 2.1, chaque automate garde une probabilité stationnaire résiduelle de se trouver « du mauvais côté », décroissant exponentiellement en N dès lors que $\rho \neq 1$ (hors régime frontière – à $\rho = 1$, cette probabilité reste exactement $\frac{1}{2}$, cf. Note « Régime frontière », Section 4) mais jamais strictement nulle pour N fini. La contradiction transitoire (les deux automates simultanément en Include) n'est donc pas structurellement impossible à tout instant ; elle est seulement exponentiellement rare pour N grand hors régime frontière. L'égalité $\Delta + \bar{\Delta} = 0$ n'a lieu que si $P(Y=1) = 0$ (aucun exemple positif) : cas dégénéré déjà identifié comme limite (*Démonstration de convergence*, Remarque sur $c = 1$).

Corollaire 3.2 (Asymétrie stricte entre littéral et négation). *Si $\Delta > 0$, alors $\bar{\Delta} = -a P(Y=1) - \Delta < 0$ strictement (et réciproquement, par symétrie du Lemme 3.1). Dès que x est asymptotiquement favorisé, $\neg x$ est strictement défavorisé – pas seulement « non favorisé ».*

4 Critère de sélection sous distribution arbitraire

Théorème 4.1 (Sélection, cas général – régimes non dégénérés). *Sous la règle à 4 cas avec $S, a > 0$ fixés, supposons les observations $(X_t, Y_t)_{t \geq 1}$ i.i.d. de loi P , et $\Delta \neq 0, \bar{\Delta} \neq 0$ (hypothèse de non-dégénérescence, cf. Note ci-dessous pour le cas frontière). Notons $\gamma = \max(\rho, 1/\rho) > 1$ et $\bar{\gamma} = \max(\bar{\rho}, 1/\bar{\rho}) > 1$ (de sorte que, par le Théorème 2.1, la probabilité que v –resp. $\bar{v}$ – soit du mauvais côté est toujours $\leq \gamma^{-N}$ –resp. $\bar{\gamma}^{-N}$ –, quel que soit le signe de Δ). Alors :*

$$\Delta > 0 \ (\rho > 1, \pi(\text{Include}) \rightarrow 1) \iff S P(0, 0) > S P(1, 0) + a P(0, 1); \quad (3)$$

$$\bar{\Delta} > 0 \ (\bar{\rho} > 1, \bar{\pi}(\text{Include}) \rightarrow 1) \iff S P(1, 0) > S P(0, 0) + a P(1, 1). \quad (4)$$

Par le Corollaire 3.2, (3) et (4) sont mutuellement exclusifs, et sous l'hypothèse de non-dégénérescence les trois régimes suivants sont exhaustifs (on énonce directement la convergence en probabilité du couple $(v_t, \bar{v}_t)$, sans invoquer une loi stationnaire jointe – la chaîne jointe $(v_t, \bar{v}_t)_t$ n'est pas nécessairement irréductible, cf. Remarque ci-après) :

- **Régime de sélection de x** : $\Delta > 0$, donc (Corollaire 3.2) $\bar{\Delta} < 0 \Rightarrow \lim_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Include}, \text{Exclude})) \leq \gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow[N \rightarrow \infty]{} 0$: la structure x est asymptotiquement préférée.
- **Régime de sélection de $\neg x$** : $\bar{\Delta} > 0$, donc $\Delta < 0 \Rightarrow \lim_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exclude}, \text{Include})) \leq \gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow[N \rightarrow \infty]{} 0$: la structure $\neg x$ est asymptotiquement préférée.
- **Régime d'exclusion des deux littéraux** : $\Delta < 0$ et $\bar{\Delta} < 0 \Rightarrow \lim_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Exclude}, \text{Exclude})) \leq \gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow[N \rightarrow \infty]{} 0$: la structure tautologique est asymptotiquement préférée, x est ignoré.

La borne $\gamma^{-N} + \bar{\gamma}^{-N}$ sur le $\lim_t$ n'est valable qu'une fois la chaîne proche de sa loi stationnaire (ou si elle y est initialisée) – elle ne dit rien sur $\mathbb{P}((v_t, \bar{v}_t) \neq \cdot)$ à un instant t petit et une initialisation arbitraire, d'où le $\lim_{t \rightarrow \infty}$ et non une égalité pour tout t . Pour tout N fini, l'automate est ergodique et fluctue selon π_N ; c'est la limite $N \rightarrow \infty$ (après celle en t) qui donne la sélection presque certaine (cf. Note terminologique, Section 2). Sous une loi $P(X, Y)$ arbitraire, la structure ainsi préférée n'est pas nécessairement la clause génératrice ni la clause Bayes-optimale – une variable peut être sélectionnée parce qu'elle est corrélée à une variable pertinente sans appartenir au concept cible.

Proof. (3) : $\Delta > 0 \iff p^+ > p^- \iff S P(0, 0) > S P(1, 0) + a P(0, 1)$ directement depuis (1). Identique pour (4). L'exclusion mutuelle et l'implication $\Delta > 0 \Rightarrow \bar{\Delta} < 0$ découlent du Corollaire 3.2. Sous $\Delta, \bar{\Delta} \neq 0$, les quatre combinaisons de signes ($\text{sgn } \Delta, \text{sgn } \bar{\Delta}$) se réduisent aux trois listées, la combinaison $(+, +)$ étant exclue par le corollaire. Passage de la convergence marginale à la convergence jointe (par exemple pour le régime IDENTITY, $\Delta > 0$, donc $\rho > 1$ et $\bar{\rho} < 1$, soit $\gamma = \rho$ et $\bar{\gamma} = 1/\bar{\rho}$) : en prenant d'abord $\lim_{t \rightarrow \infty}$ (le Théorème 2.1 borne la loi stationnaire, atteinte seulement asymptotiquement en t depuis une initialisation arbitraire – l'inégalité ci-dessous serait fausse pour un t petit), puis par union bound,

$$\lim_{t \rightarrow \infty} \mathbb{P}((v_t, \bar{v}_t) \neq (\text{Include}, \text{Exclude})) \leq \lim_{t \rightarrow \infty} \mathbb{P}(v_t \neq \text{Include}) + \lim_{t \rightarrow \infty} \mathbb{P}(\bar{v}_t \neq \text{Exclude}) \leq \gamma^{-N} + \bar{\gamma}^{-N} \xrightarrow[N \rightarrow \infty]{} 0$$

sans jamais supposer l'indépendance de v_t et $\bar{v}_t$ (l'union bound ne requiert que les bornes marginales du Théorème 2.1, valables même si v_t et $\bar{v}_t$ sont corrélés). Les deux autres régimes se traitent de façon identique. *Attention* : $\bar{\gamma}^{-N} = \bar{\rho}^N$ ici (et non $\bar{\rho}^{-N}$, puisque $\bar{\rho} < 1$) – c'est pour éviter précisément cette confusion de signe que $\gamma = \max(\rho, 1/\rho)$ est défini une fois pour toutes, indépendamment du sens de la préférence. $\square$

[Non-irréductibilité possible de la chaîne jointe] La chaîne $(v_t, \bar{v}_t)_t$ est bien une chaîne de Markov homogène (les deux composantes sont mises à jour par la même observation (X_t, Y_t) i.i.d. à chaque pas), mais elle n'est pas nécessairement irréductible sur

$\{1, \dots, 2N\}^2$ tout entier : par exemple avec $S = 1$ et $P(Y=1) = 0$, une poussée vers Include sur v s'accompagne toujours d'une poussée vers Exclude sur $\bar{v}$ (et réciproquement), de sorte que $v_t + \bar{v}_t$ est conservé tant qu'aucun des deux automates n'atteint une borne – la chaîne jointe reste alors confinée à une sous-classe déterminée par l'initialisation. C'est précisément pour cette raison que la preuve ci-dessus évite d'invoquer une loi stationnaire jointe Π_N et travaille directement avec $\lim_t \mathbb{P}((v_t, \bar{v}_t) \neq \cdot)$, borné via l'union bound sur les deux marginales seules – un argument qui ne requiert aucune irréductibilité de la chaîne jointe.

Note 4.1 (Régime frontière $\Delta = 0$ ou $\bar{\Delta} = 0$). Si l'hypothèse de non-dégénérescence est levée, $\Delta = 0$ donne $\rho = 1$ et, par le Théorème 2.1, $\pi(\text{Include}) = \frac{1}{2}$: l'automate correspondant n'a stationnairement *aucune* préférence – ni convergence vers Include, ni vers Exclude – contrairement à ce qu'impliquerait une lecture naïve de « les deux inégalités sont fausses ». Ce cas frontière correspond à une égalité exacte entre deux quantités continues de $P(X, Y)$ et est donc de mesure nulle pour une loi jointe générique, mais il doit être exclu explicitement (hypothèse $\Delta, \bar{\Delta} \neq 0$) pour que les trois régimes du Théorème 4.1 soient effectivement exhaustifs et mutuellement exclusifs.

Note 4.2 (Unification de deux résultats déjà établis). Ce théorème unique remplace et généralise à la fois le résultat sur le « littéral pertinent » (*Convergence de la clause conditionnée*, Théorème 3.1, cas $p_1 \neq p_0$ dans la notation (c, p_1, p_0) de cette référence, où elle écrit a, b) et celui sur la « neutralité » (*ibid.*, Théorème 4.2, cas $p_1 = p_0 = p_y$ restreint) : les deux étaient des cas particuliers de la même paire d'inégalités (3)–(4), simplement exprimées dans la paramétrisation (c, p_1, p_0) plutôt qu'en $P(X, Y)$ général. Le seuil $S_{\text{bas}}(j)$ et le seuil S_i^{max} déjà publiés se retrouvent en isolant S dans (3) pour les deux régimes $P(0, 1) > 0$ (seuil bas) ou distribution symétrique (seuil haut) — calcul inchangé, notation unifiée.

5 Extension multi-bit : borne de concentration pour une clause

Théorème 5.1 (Concentration multi-bit). *Soit une clause à n features, dont K fixées par la condition ; les $d = n - K$ restantes sont gouvernées par $2d$ automates. Pour chaque automate j , en supposant sa préférence stationnaire non dégénérée, notons $r_j = p_j^+ / p_j^-$, $\gamma_j = \max(r_j, 1/r_j) > 1$, et $\gamma_{\min} = \min_{1 \leq j \leq 2d} \gamma_j$. Notons C^* la structure préférée sous P (Théorème 4.1) et C_t la clause effectivement calculée à l'instant t . Alors, sans hypothèse d'indépendance entre automates :*

$$\lim_{t \rightarrow \infty} \mathbb{P}(C_t \neq C^*) \leq \sum_{j=1}^{2d} \frac{1}{1 + \gamma_j^N} \leq 2(n - K) \cdot \gamma_{\min}^{-N}.$$

Proof. Si $C_t \neq C^*$, au moins un des $2(n - K)$ automates est du mauvais côté. Le résultat suit de la borne stationnaire à un seul automate (Théorème 2.1) et de l'union bound, qui ne requiert aucune indépendance entre les automates (juste leurs bornes marginales). $\square$

Note 5.1 (Cas exclus et portée du résultat). Le cas frontière $r_j = 1$ et le cas dégénéré $p_j^+ = p_j^- = 0$ (aucun signal) sont exclus par l'hypothèse de non-dégénérescence, en

cohérence avec $\Delta, \bar{\Delta} \neq 0$ du Théorème 4.1 ; un automate absorbant (Corollaire 2.2) est couvert par la convention $\gamma_j = \infty$. La borne utilise nécessairement le *pire* automate ($\gamma_{\min}$), pas le meilleur. Enfin, $C_t \neq C^*$ est un *mismatch structurel* (deux structures différentes peuvent calculer la même fonction logique par coïncidence), pas nécessairement une erreur de classification ; et la borne porte sur la clause interne conditionnelle, la condition elle-même étant fixée par construction (sa couverture fait l’objet d’un résultat séparé, Section 6).

Note 5.2 (Lien avec le conditionnement K). La loi $P(X, Y)$ de la Section 1 est ici la loi conditionnelle sur le sous-ensemble applicable D_F (les exemples satisfaisant la condition sur les K features gelées). Sans conditionnement ($K = 0$, donc $d = n$), le théorème s’applique tel quel à la clause entière – mais rien ne garantit alors que chaque littéral individuel tombe dans le régime « pertinent » plutôt que « neutre » pour une cible à $m \geq 2$ littéraux : c’est exactement la limite déjà documentée (échec de `hybrid_coord_4case.cpp`, test $K=0$ sur Iris à 22,7 %, sous le hasard).

6 Couverture des conditions aléatoires : garantie d’ensemble

Il faut séparer nettement deux sources d’erreur bien distinctes : (1) la probabilité de *tirer une bonne condition* (propriété fixe, déterministe une fois F, v choisis) et (2) sachant la condition bonne, la probabilité que la clause associée *apprenne effectivement* la bonne structure (propriété probabiliste, dépendant de N et t – déjà bornée par le Théorème 5.1). Cette section formalise la première, puis les combine, reliant M, K, n et N au ratio $M/(2^K \binom{n}{K})$ déjà observé empiriquement (Section 8).

Il existe $C_K = 2^K \binom{n}{K}$ conditions possibles : le choix de K features parmi n , et une valeur binaire pour chacune.

Définition 6.1 (Condition utile). *Fixons un concept cible (un sous-ensemble de littéraux pertinents parmi les n). Une condition (F, v) , $F \subseteq \{1, \dots, n\}$, $|F| = K$, $v \in \{0, 1\}^K$, est dite utile pour ce concept si, sous la loi conditionnelle $P(X, Y \mid X_F = v)$, la règle sélectionne correctement (au sens du Théorème 4.1) les littéraux cibles parmi les $n - K$ features non fixées. Notons $G^* \geq 1$ le nombre de conditions utiles parmi les C_K possibles (hypothèse d’identifiabilité minimale : au moins une condition révèle le concept), et*

$$q = \frac{G^*}{C_K} = \frac{G^*}{2^K \binom{n}{K}}$$

la probabilité qu’une condition tirée uniformément soit utile.

Théorème 6.2 (Couverture des conditions utiles). *Si les M clauses tirent leur condition indépendamment et uniformément (garanti par le code : `shuffle(pool.begin(), pool.end(), rng)` donne un sous-ensemble de K features uniforme, et `vals.push_back(valDist(rng, vals))` tire chaque valeur par un pile-ou-face indépendant) :*

$$\mathbb{P}(\text{au moins une condition utile est tirée}) = 1 - (1 - q)^M \geq 1 - e^{-Mq}.$$

Proof. Chaque clause tire une condition utile avec probabilité q , indépendamment

des autres. La probabilité qu'aucune des M clauses n'en tire une vaut $(1 - q)^M$; le complémentaire donne l'égalité, et $1 - q \leq e^{-q}$ donne la forme exponentielle. $\square$

Corollaire 6.3 (Garantie de présence d'une clause correcte). *Supposons que, pour toute condition utile, la probabilité (asymptotique en t) que la clause apprise soit structurellement incorrecte soit bornée par $\varepsilon_N = 2(n - K)\gamma_{\min}^{-N}$ (Théorème 5.1). Alors, par union bound sur les deux complémentaires (« aucune condition utile tirée », Théorème 6.2 ; et, pour une clause ayant reçu une condition utile, « elle n'apprend pas la bonne structure », Théorème 5.1) :*

$$\mathbb{P}(\text{l'ensemble contient au moins une clause correcte}) \geq 1 - e^{-Mq} - \varepsilon_N = 1 - e^{-Mq} - 2(n - K)\gamma_{\min}^{-N}.$$

Note 6.1 (Deux sources d'erreur distinctes, et ce que ça ne prouve pas). Point important : ne pas appeler une clause « utile » avant son entraînement – *la condition est utile* (propriété fixe de P et du concept cible, indépendante de N et t), *puis* la clause peut être apprise correctement ou non (propriété probabiliste du Théorème 5.1). Ce corollaire garantit seulement l'existence d'*au moins une* clause correcte dans l'ensemble, pas que le vote final (pondéré par α_m , Section 6) la retient effectivement ni qu'elle domine les autres clauses au moment du classement. Combiner cette garantie de couverture avec une garantie sur le poids relatif α_m des clauses correctes reste un travail futur.

7 Analyse par round sous les distributions induites par le boosting

Théorème 7.1 (Caractérisation conditionnelle d'un round de boosting – distribution d'entraînement effective Q_m). *Soit, au round m , S_m le sous-ensemble applicable de la clause (les exemples satisfaisant son conditionnement) et w_i les poids AdaBoost courants sur S_m . Notons $W_m^+ = \sum_{i \in S_m: y_i=1} w_i$ et $W_m^- = \sum_{i \in S_m: y_i=0} w_i$. Le code d'entraînement (`modele_xor.cpp`, `modele_multiclasse.cpp`) ne tire pas directement selon la distribution pondérée $D_m(i) = w_i / \sum_{j \in S_m} w_j$: il choisit d'abord la classe positive ou négative avec probabilité $\frac{1}{2}$ chacune si les deux sont non vides, sinon il échantillonne exclusivement dans l'unique classe présente ; si S_m est vide, la clause n'est pas entraînée du tout ($\alpha_m = 0$, if (`subsetIdx.empty()`) { `alphas.push_back(0.0)`; `continue`; }). La distribution réellement échantillonnée pour mettre à jour les automates est donc*

$$Q_m(i) = \begin{cases} \frac{1}{2} \cdot \frac{w_i}{W_m^+}, & i \in S_m, y_i = 1, W_m^+ > 0, W_m^- > 0, \\ \frac{1}{2} \cdot \frac{w_i}{W_m^-}, & i \in S_m, y_i = 0, W_m^+ > 0, W_m^- > 0, \\ \frac{w_i}{W_m^+}, & i \in S_m, y_i = 1, W_m^- > 0 \text{ faux (sous-ensemble pur positif)}, \\ \frac{w_i}{W_m^-}, & i \in S_m, y_i = 0, W_m^+ > 0 \text{ faux (sous-ensemble pur négatif)}, \\ 0, & i \notin S_m, \end{cases}$$

non définie (clause ignorée, $\alpha_m = 0$) si $W_m^+ = W_m^- = 0$ (i.e. $S_m = \emptyset$). Conditionnellement à l'historique du boosting et au tirage aléatoire du stump (sous-ensemble conditionnant) du round m , et sur l'évènement $S_m \neq \emptyset$, les Théorèmes 2.1, 4.1, 5.1

s'appliquent à la clause m , chacun sous ses hypothèses respectives, avec $P(X, Y)$ remplacée par $Q_m(X, Y)$ – et non par D_m . En particulier, sur un sous-ensemble pur ($W_m^+ = 0$ ou $W_m^- = 0$) ou proche de la frontière ($r_j \approx 1$ pour certains automates j), certains littéraux de la clause m peuvent relever du Corollaire 2.2 (absorbant) plutôt que du régime ergodique du Théorème 2.1, ou se trouver dans le régime frontière exclu du Théorème 4.1 ; le Théorème 5.1 ne s'applique alors qu'aux littéraux non dégénérés de la clause m .

Proof. Les probabilités de transition (1)–(2) sont des fonctions linéaires de la loi utilisée pour générer les tirages effectivement présentés à l'automate ; substituer Q_m à P ne change aucune étape des preuves précédentes, qui ne supposent jamais une forme particulière de P . Q_m , et non D_m , est la loi qui génère les (x, y) réellement vus par `updateMasked` pendant le round m : la ligne `useNeg = subNeg.empty() ? false : (subPos.empty() ? true : !flip(0.5))` donne exactement les quatre cas ci-dessus (rééquilibré si les deux classes sont présentes, sinon échantillonnage pur dans l'unique classe présente). D_m n'intervient nulle part dans cette mise à jour, uniquement dans le calcul de l'erreur pondérée (`err += w[i]`, puis `err /= wSum`) et de α_m . $\square$

Note 7.1 (Q_m pour l'apprentissage, D_m pour l'évaluation). Le rééquilibrage 50/50 (tirer selon Q_m plutôt que D_m) est un choix de conception délibéré : il évite qu'une classe majoritaire domine l'entraînement de la clause. Mais l'erreur pondérée $\text{err} = (\sum_i w_i \mathbf{1}[\text{faux}]) / \sum_i w_i$ et le coefficient $\alpha_m = \frac{1}{2} \ln \frac{1-\text{err}}{\text{err}}$ sont eux calculés sous D_m , la vraie distribution AdaBoost non rééquilibrée. Le Théorème 7.1 caractérise donc la clause m elle-même sous Q_m ; la qualité du weak learner (son erreur, son poids α_m dans le vote final) est mesurée sous D_m . Ce n'est pas une incohérence du code, mais une distinction nécessaire entre « ce qui entraîne la clause » et « ce qui évalue sa qualité » – absente d'une version antérieure de ce document, qui remplaçait P par D_m partout, y compris pour caractériser l'entraînement lui-même.

Note 7.2 (Ce que ce théorème ne prouve pas). Il caractérise chaque round *isolément*, conditionnellement à Q_m — il ne prouve pas la convergence de l'ensemble $F_c(x) = \sum_m \alpha_{c,m} h_{c,m}(x)$ vers un classifieur de Bayes global, ce que l'AdaBoost classique établit sous des hypothèses différentes (voir Related Work). Nous ne revendiquons pas ce résultat plus fort.

Note 7.3 (Weak learner abstentionniste). Le weak learner h_m associé à la clause m n'est pas un classifieur binaire standard : il s'abstient (vote nul) hors de S_m . En notation $\{-1, 0, +1\}$, $h_m(x) = 0$ pour $x \notin S_m$. L'erreur pondérée $\text{err}_m = (\sum_{i \in S_m} w_i \mathbf{1}[h_m(x_i) \neq y_i]) / \sum_{i \in S_m} w_i$ et $\alpha_m = \frac{1}{2} \ln \frac{1-\text{err}_m}{\text{err}_m}$ sont donc les formules standard d'AdaBoost à *classifieurs abstentionnistes* (restreintes à S_m), pas celles d'AdaBoost classique sur l'ensemble complet des exemples.

Note 7.4 (Écart entre la structure caractérisée et le weak learner conservé). Les Théorèmes 4.1 et 5.1 caractérisent la structure C^* vers laquelle les automates de la clause m convergent – y compris le régime « exclusion des deux littéraux » pour *chacun* des $d - K$ littéraux libres, qui correspond à une clause *structurellement vide* si tous les littéraux libres y tombent simultanément. Le code ne traite cependant pas une clause vide comme le prescrit la convention usuelle des Tsetlin Machines (sortie 1 à l'entraînement, 0 au test, cf. Granmo 2018, Eq. 6) : il la détecte après coup (`isEmpty()`) et l'écarte purement et

simplement du vote final ($\alpha_m = 0$, clause ignorée). Les Théorèmes 2.1–5.1 décrivent donc la structure vers laquelle *chaque* clause converge, mais pas l’étape de sélection supplémentaire (garder/écarter) qui détermine l’ensemble effectif de weak learners utilisés par le classifieur final ; cette étape n’est pas couverte par les théorèmes ci-dessus et resterait à formaliser séparément (par exemple en conditionnant explicitement sur l’évènement « clause non vide »).

8 Validation empirique — déjà réalisée

La courbe $N \mapsto \pi(\text{Include}) = \rho^N / (1 + \rho^N)$ (Théorème 2.1) et le seuil critique $\alpha^*(S)$ issu du Théorème 4.1 ont été confrontés à des données réelles sur **quatre** datasets (*Rôle de S et α : théorie et validation* – ce document utilise encore la notation α pour ce même paramètre, ici renommé a pour éviter la collision avec α_m) :

- XOR : 42 configurations, accord exact sur la position du seuil (mur d’effondrement prédit à $\alpha^*(S) = 0,519S$, confirmé configuration par configuration) ;
- Iris, Digits, MNIST : confirment que la sensibilité observée dépend du ratio $M / (2^K \binom{n}{K})$ (nombre de clauses / nombre total de conditions possibles – le choix des K features *et* d’une valeur binaire pour chacune, cf. `vals.push_back(valDist(rng))` dans `modele_multiclasse.cpp` : le nombre de combinaisons de features seul, $\binom{n}{K}$, sous-compte d’un facteur 2^K), avec un test direct ($M=500 \rightarrow 16\,000$ sur MNIST) confirmant que l’écart se réduit quand ce ratio augmente.

Le classifieur multiclassés boosté (Théorème 7.1) a par ailleurs déjà été comparé à SVM, Régression Logistique, Random Forest et MLP sur Iris, Digits et MNIST, avec des résultats égalant ou dépassant ces baselines sur Iris et Digits (voir document de suivi des expériences).